СОДЕРЖАНИЕ

ВВЕДЕНИЕ 2
1. Биологические языковые модели обучения представлений 6
1.1. Биологические последовательности как язык 6
1.2. Методы кодирований последовательностей 7
1.2.1. Разреженное кодирование 8
1.2.2. Физико-химические свойства 8
1.2.3. Частотные векторные представления 12
1.2.4. Контекстуальные векторные представления 13
1.3. Языковые модели белков 15
1.3.1. Архитектуры моделей 16
1.4. Существующие методы сравнения векторных представлений 20
1.5. Ограничения методов сравнений 21
Выводы по главе 1 22
2. Разработка метода сравнительного анализа векторных представлений . 23
2.1. Методы измерения сложности наборов данных 23
2.1.1. Сложность задач классификации табличных данных 23
2.1.2. Сложность задач классификации текстовых данных 27
2.1.3. Характеристики разнообразия аминокислотных последовательностей 29
2.2. Базовая сложность набора данных 32
2.3. Кластеризация 35
2.4. Корректное сравнение векторных представлений 39
Выводы по главе 2 41
3. Реализация и анализ алгоритма для сравнительного анализа биологических языковых моделей 42
3.1. Контрольные наборы данных 42
3.2. Расчет характеристик сложности 42
3.3. Анализ характеристик сложности 44
3.4. Анализ кластеров сложности 46
3.5. Сравнение векторных представлений передовых биологических языковых моделей 47
Выводы по главе 3 48

ЗАКЛЮЧЕНИЕ 49
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ 50
ПРИЛОЖЕНИЕ А. Используемые наборы данных 62

ВВЕДЕНИЕ

Современные языковые модели демонстрируют высокую результативность в широком спектре задач биоинформатики. Они обеспечивают возможность извлекать значимую информацию о характеристиках объектов непосредственно из биологических последовательностей, которые являются наиболее распространенным и доступным источником данных по сравнению с методами моделирования вторичных[1] и третичных[2] структур. Источником такой информации выступают векторные представления, извлеченные из языковых моделей. Оценка информативности таких представлений обычно происходит через выявление их прикладной полезности. Например, узнать несут ли представления извлеченные из языковой модели информацию о токсичности молекулы, можно посредством построения простой модели машинного обучения для решения задачи бинарной классификации. Такая модель будет обучена различать токсичные и нетоксичные молекулы. Принято считать, что метрики качества такой модели отражают наличие в векторных представлених релевантной информации.

Однако, сравнительный анализ подобных векторных представлений попрежнему представляет собой нерешенную методологическую задачу. Существующие подходы к сопоставлению моделей на эталонных наборах данных, как правило, опираются на использование ограниченных, выборочных и варьирующихся от работы к работе наборов с последующим усреднением метрик качества заранее определенного ряда моделей машинного обучения. Несмотря на простоту и широкую распространенность, подобный подход обладает рядом существенных ограничений, включая отсутствие стандартизации бенчмарков и игнорирование различий в сложности решаемых задач.

Одна из ключевых проблем заключается в том, что использованные наборы данных в бенчмаркинге могут существенно различаться по своей природе и сложности. Например, задачи могут различаться по степени разделимости классов, уровню шума в данных, а также разнообразию биологических последовательностей включенных в набор. При этом, в существующих работах, вклад каждого набора данных в итоговую оценку векторных представлений

[1]Вторичная структура биополимера — локальная пространственная организация биологической макромолекулы (белка, РНК или ДНК), формируемая за счет водородных связей между атомами остова и характеризующаяся регулярными элементами, такими как -спирали, -листы и петли (для белков) или стебель-петля (для РНК).

[2]Третичная структура биополимера — трехмерная пространственная конфигурация всей молекулы, формируемая в результате взаимодействий между удаленными участками цепи.

равнозначен, из чего следует потенциальное смещение результатов, где векторные представления, показавшие высокую производительность на простых задачах, могут получать завышенные оценки, тогда как представления, демонстрирующие устойчивость на более сложных задачах, оказываются недооцененными.

В связи с этим актуальным направлением становится разработка подхода, позволяющего учитывать сложность наборов данных при сравнении векторных представлений языковых моделей. Основная идея подхода в данной работе заключается в том, что вклад каждого набора в итоговую оценку векторных представлений должен определяться не только значением метрики качества базовых моделей на этом наборе, но и сложностью соответствующей задачи. Это позволяет перейти от простого усреднения к более информативной и обоснованной процедуре агрегирования.

Целью дипломной работы является разработка метода сравнительного анализа векторных представлений с использованием алгоритмов машинного обучения, отличающегося тем, что с целью повышения корректности и интерпретируемости результатов сравнения, учитывается сложность используемых наборов данных, а также вводится взвешенная процедура агрегирования метрик качества, отражающая вклад каждой задачи в итоговую оценку.

Для достижения поставленной цели в работе решаются следующие задачи:

а) Формирование репрезентативного ряда эталонных наборов данных для задач бинарной классификации в области предсказания свойств пептидов.

б) Разработка системы признаков, описывающих сложность набора данных. В рамках работы рассматриваются два основных аспекта сложности:
   - сложность классификации (разделимость классов, плотностные характеристики, энтропийные меры и т. п.);
   - доменная информативность (разнообразие последовательностей, распределение длин и т. п.).

в) Разработка и применение базового подхода к оценке сложности через качество работы простых моделей, исходя из предположения, что более

сложные наборы данных приводят к ухудшению результатов таких моделей.

г) Анализ взаимосвязей между признаками сложности и качеством базовых моделей, включая отбор информативных признаков.

д) Группировка наборов данных по уровню сложности с использованием методов кластеризации и проверка статистической значимости различий между полученными группами.

е) Разработка метода взвешенного бенчмаркинга, в котором вклад датасетов в итоговую оценку модели определяется их сложностью.

ж) Экспериментальная проверка предложенного подхода на ряде современных белковых языковых моделей и анализ изменения результатов по сравнению с традиционным усреднением.

Научная новизна работы заключается в явном введении и формализации понятия сложности набора данных в контексте бенчмаркинга белковых языковых моделей, а также в разработке метода взвешенного сравнения, позволяющего учитывать данную характеристику при оценке моделей.

Практическая значимость работы определяется тем, что предложенный подход позволяет получать более объективные и интерпретируемые результаты сравнительного анализа, а также выявлять модели, демонстрирующие повышенную эффективность на сложных задачах. В свою очередь, это способствует более обоснованному выбору моделей для решения прикладных задач биоинформатики.

Таким образом, в рамках данной работы предлагается переход от традиционного, упрощенного подхода к сравнению моделей к более гибкой и информативной методологии, учитывающей неоднородность и сложность используемых данных.

В ходе данной работы автор выступил на «XV Конгресс молодых ученых ИТМО» с докладом по теме исследования.

В первой главе проведен обзор языковых моделей биологических последовательностей и существующих подходов к оценке сложности задач классификации через анализ наборов данных.

Во второй главе предложен подход к формированию метода сравнения векторных представлений и оценки сложности наборов данных, содержащих пептидные последовательности.

В третьей главе представлены результаты проведения экспериментов и итоговый метод сравнения векторных представлений. Также проведено сравнение классического метода усреднения метрик качества с предложенным подходом на ряде современных белковых языковых моделей.

ГЛАВА 1. БИОЛОГИЧЕСКИЕ ЯЗЫКОВЫЕ МОДЕЛИ ОБУЧЕНИЯ ПРЕДСТАВЛЕНИЙ

1.1. Биологические последовательности как язык

Биологические последовательности - это первичные структуры биологических молекул, которые представляют линейную последовательность структурных единиц. Для белков и пептидов структурной единицей выступают аминокислоты, а для ДНК и РНК — нуклеотиды. На практике каждая наименьшая структурная единица выражается однобуквенным кодом определенным на основе биохимической номенклатуры IUPAC-IUBMB для стандартизации записи биологических последовательностей [98]. Первичная структура служит фундаментальным уровнем организации и определяет пространственную структуру[1], которые в свою очередь определяют множество биологических функций [111].

В задачах биоинформатики и вычислительной биологии основной и наиболее доступной формой представления биологических объектов являются их последовательности – нуклеотидные (ДНК и РНК) и аминокислотные (белки и пептиды). В отличие от трёхмерной структуры, функциональной аннотации и экспериментально измеренных свойств, получение которых связано со значительными временными и материальными затратами, последовательности могут быть определены относительно быстро и в больших объёмах благодаря развитию современных технологий секвенирования. Более того, во многих случаях последовательность остаётся единственным доступным источником информации об объекте, особенно для недавно открытых или плохо изученных молекул. В связи с этим разработка методов извлечения информативных признаков непосредственно из последовательностей является ключевой задачей, позволяющей компенсировать нехватку экспериментальных данных.

С развитием методов обработки естественного языка в литературе биологические последовательности всё чаще рассматриваются как особый тип языка, обладающий собственной «грамматикой», которая отражает эволюционные, структурные и функциональные ограничения, накладываемые на биологические последовательности [75, 95]. В рамках такой парадигмы структурная единица интерпретируется как элемент алфавита, а целая последователь-

[1]Пространственная структура биополимера — трехмерная организация биологической макромолекулы, описывающая расположение ее атомов в пространстве и определяющая функциональные и физико-химические свойства молекулы.

ность — как строка символов, аналогичная предложению в естественном языке [83].

Принято считать, что функциональные закономерности в последовательностях не задаются явно, но могут быть извлечены из больших корпусов биологических данных с использованием методов машинного обучения. Так, в результате обучения модели формируют векторные представления биологических последовательностей, в которых в неявном виде кодируются их свойства. Эти представления служат универсальным видом данных, на основе которого могут обучаться последующие модели машинного обучения для решения прикладных задач. Анализируя их, модели способны выявлять наличие или отсутствие тех или иных биологических свойств [37, 95].

1.2. Методы кодирований последовательностей

Сами по себе биологические последовательности представлены в символьной форме и не могут быть напрямую использованы в алгоритмах машинного обучения. Поэтому необходим этап их преобразования в числовые представления — кодирование, которое позволяет сохранить релевантную биологическую информацию (например, состав, порядок, физико-химические свойства или эволюционные характеристики аминокислот) в виде векторов признаков. Качество такого кодирования во многом определяет эффективность последующего анализа и моделирования.

Методы кодирования последовательностей находят применение в широком спектре задач. К ним относятся классификация биологических объектов по функциональным свойствам (например, выявление антимикробных и противовирусных свойств), предсказание пространственных структуры, анализ взаимодействий с другими молекулами, а также оценка биологической активности, токсичности и фармакокинетических характеристик. Кроме того, такие представления используются для поиска гомологичных последовательностей[2], аннотации геномов[3] и выявления функциональных мотивов[4]. Таким

[2]Гомологичная последовательность — биологическая последовательность, имеющая общее эволюционное происхождение с другой последовательностью, что обычно проявляется в их сходстве по структуре и/или функции.

[3]Аннотация геномов — процесс выявления и описания функциональных элементов генома (таких как гены, регуляторные участки и другие значимые последовательности) с использованием вычислительных и экспериментальных методов.

[4]Функциональные мотивы — относительно короткие консервативные участки биологических последовательностей, связанные с выполнением определённых биологических функций, например, связыванием молекул или каталитической активностью.

образом, эффективное кодирование последовательностей является фундаментальным этапом, связывающим сырые биологические данные с современными методами машинного обучения и анализа данных.

1.2.1. Разреженное кодирование

Один из самых простых подходов к представлению биологических последовательностей в векторном виде — это разреженное кодирование, также называемое бинарным кодированием. Разреженное кодирование — это векторное представление дискретной переменной, обычно используемое для дискретных значений, не имеющих осмысленного порядка. При разреженном кодировании каждая структурная единица представляется в виде вектора горячего кодирования, где каждая позиция, кроме одной, устанавливается равной нулю. Для кодирования целой биологической последовательности эти вектора часто последовательно объединяются.

Так как модели машинного обучения требуют фиксированный размер входных данных на уровне образца, а длина вектора разреженного кодирования напрямую зависит от длины последовательности, исследователи часто прибегают прибегают к корректировкам последовательностей перед кодированием. Это происходит либо посредством множественного выравнивая, либо попарного выравнивания последовательностей относительно эталонной последовательности. Выравнивания могут разрывать последовательность в любом месте, вставлять пробелы и удалять символы. Для заполнения пробелов обычно используется дополнительный специальный символ. Еще одним популярным подходом является добавление отступов, то есть дополнение векторов нулями до максимальной длины. Все это делает данные методы достаточно грубыми приближениями и может влиять на результат исследований [106].

Такое кодирование не несет никакой информации кроме представления самой последовательности и информации о порядке структурных единиц [116]. Несмотря на это, разреженное кодирование нашло применение во многих работах в области, например для прогнозирования вторичных структур белков [47], сродства связывания пептидов [100] и модуляции антигенпрезентирующих клеток [25].

1.2.2. Физико-химические свойства

База данных индексов аминокислот (AAindex) является специализированным ресурсом, направленным на количественное описание различных

свойств аминокислот и их взаимодействий [4]. Она широко используется в биоинформатике, так как организованна как единый структурированный источник числовых дескрипторов, который позволяет переводить качественные биохимические признаки в форму, удобную для вычислительного анализа. AAindex разделена на три основные части, каждая из которых отражает соответствующие уровни представления информации об аминокислотах.

Первый раздел (AAindex1) содержит дескрипторы, отвечающие за индивидуальные физико-химические свойства аминокислот. К таким свойствам относится информация о гидрофобности, полярности, заряда, значения изоэлектрической точки, объема боковой цепи, склонность к образованию вторичных структур, а также термодинамические параметры, такие как энергия взаимодействия с растворителем. Каждая характеристика представлена в виде вектора из двадцати значений, где каждое значение соответствуют одной из двадцати стандартных аминокислот.

Второй раздел (AAindex2) представляет матрицы замещения, которые несут информации о возможностях замен одной аминокислоты на другую учитывая процессы эволюции. Такая информация является ключевой в процессах выравнивания, анализе гомологии и скрининговых исследованиях. Наиболее известной матрицей замещения является BLOSUM62 [34], которая включена в AAindex2. BLOSUM62 построена на основе наблюдаемых замен аминокислот в консервативных участках белковых последовательностей и часто используется как стандарт в алгоритмах выравнивания. Числовые значения здесь выражают логарифмическое отношения вероятностей конкретной замены к вероятности случайной. Если замена происходит чаще, чем случайно, то значение положительно, если реже - отрицательно.

Третий раздел (AAindex3) описывает взаимодействия между парами аминокислот, которые находятся в непосредственной пространственной близости в трехмерной структуре белка. Такое взаимодействие выражается через контактные потенциалы, которые основаны на эмпирических оценках изменения свободной энергии Гиббса при частых контактах остатков. Данная информация позволяет моделировать стабильность белковых структур.

Для применения подобных дескрипторов в машинном обучение используется ряд методов для описания полноценных последовательностей. Наиболее популярным способом является преобразование буквенных последова-

тельностей в матричный вид, где на позиции каждой кислоты встает вектор интересующих дескрипторов.

В связи с тем, что AAindex предоставляет порядка 566 физико-химических признаков для каждой аминокислоты, использование всех этих признаков единовременно приводит к избыточности и высокой размерности данных. Однако, для решение подобной проблемы существуют z-дескрипторы, которые являются проекцией исходного пространства свойств в более компактное подпространство, посредством применения метода частичных наименьших квадратов [82]. Такое подпространство зачастую состоит из пяти компонент, которые являются линейной комбинацией исходных физико-химических дескрипторов. Первые три компоненты принято рассматривать как гидрофобность, объем боковой цепи и полярность, а последующие компоненты не поддаются четкому определению в связи с более тонкими и комбинированными эффектами взаимодействия свойств.

Еще одним популярным подходом в биоинформатике является отношение к биологическим структурным единицам как к отдельным молекулам, так как мы можем выразить любую аминокислоту и нуклеиновую кислоту в виде формулы SMILES. Таким образом появляется возможность интегрировать молекулярные дескрипторы в описание последовательностей. Одним из наиболее популярных ресурсов в этой сфере является RDKit [96]. Он широко используется для анализа и визуализации молекулярных структур. Однако наиболее интересным преимуществом является возможность генерировать и вычислять физико-химические и структурные дескрипторы на основе SMILES[5]. Данный ресурс предоставляет сорок три дескриптора, которые включают молекулярную массу, логарифм коэффициента распределения logP, число доноров и акцепторов водородных связей, площадь топологической полярной поверхности и другие. Кроме того, RDKit поддерживает генерацию молекулярных отпечатков Моргана, которые кодируют структуру молекулы в виде бинарных или счетных векторов.

Вышеуказанные методы подвержены проблеме разных длин последовательностей в наборе данных, так как итоговые представления напрямую зависят от числа структурных единиц. Для решения этой проблемы дополнительно может применяться агрегация признаков [42]. Наиболее распространенны-

[5]SMILES (Simplified Molecular Input Line Entry System) — система символьного представления химических структур, позволяющая однозначно описывать состав и строение молекул с использованием строк ASCII.

ми методами являются усреднение значений дескрипторов по всей последовательности, вычисления скользящих окон для выравнивания локальных паттернов или использование статистик, например, среднее, дисперсия и другие. Такой подход позволяет получать «средний» профиль представления последовательностей, что приводит к потере информации о локальной структуре. Однако полученные профили являются удобными входами для классических алгоритмов машинного обучения и хорошо показали себя на задачах классификации антимикробных пептидов [26].

С целью сохранить больше информации о свойствах, чем это возможно с усреднением, применяются методы интерполяции [43]. Интерполяция последовательности заключается в преобразовании дискретного сигнала, где каждой позиции в последовательности сопоставлен z-дескриптор, в непрерывную функцию с помощью различных линейных или нелинейных интерполяций. Такой способ позволяет получать непрерывные вектора единой размерности для последовательностей разных длин благодаря дальнейшему сэмплированию фиксированного числа точек из полученных функций [43, 45].

Альтернативным подходом является использование d-дескрипторов, разработанных для оценки терапевтического индекса пептидов [23]. Этот метод основан на концепции «моментов последовательности», которые вычисляются путем сворачивания аминокислотной последовательности под заранее заданным углом в условном двумерном пространстве. Каждой аминокислоте в таком пространстве сопоставляется вектор, длина которого определяется значением выбранного физико-химического свойства (например, гидрофобности), а направление — ее положением в последовательности и заданным углом поворота. Далее рассчитываются два результирующих вектора суммарных «моментов последовательности»: один с использованием шкалы гидрофобности Янина, а другой — шкалы Гая. Угол между этими двумя векторами определяется как d-дескриптор. В данной работе было показано, что d-дескриптор линейно коррелирует с терапевтическим индексом пептидов и может использоваться для предсказания изменений их селективности при точечных мутациях.

В современных подходах такие представления последовательностей могут подаваться на вход нейронным сетям, включая сверточные и рекуррентные архитектуры [41, 79].

1.2.3. Частотные векторные представления

K-меры[6] представляют собой набор всех возможных комбинаций аминокислот длины k, которые можно извлечь из исходной биологической последовательности. В контесте текстовых данных можно провести аналогию с моделью «мешка слов»[7], которая преобразует входную последовательность в набор признаков на основе частоты встречаемости ее структурных элементов [83]. Основной концепцией данной модели является идея, что похожие предложения имеют соответствующий набор слов без учета их порядка. Возвращаясь к терминам биоинформатики, предполагается, что подсчет частотной статистики на структурных единицах может отражать информацию об исходной последовательности. Таким образом, мы можем получить из последовательности вектор, длина которого формируется из числа уникальных структурных единиц, а значения вычисляются подсчетом встреч конкретной единицы в последовательности. Для повышения информативности такие вектора можно нормировать на общую длину последовательности или использовать схемы TF-IDF[8] [102].

В биоинформатике данный подход широко применяется для анализа последовательностей, так как длина выходного вектора является фиксированной, что делает представление удобным для применения классических моделей машинного обучения [70, 77, 84]. Однако, стоит отметить, что рост числа k, неизбежно приводит к экспоненциальному росту размерности признакового пространства. Например, если использовать все канонические аминокислоты и установить длину k-мера равной четырем, мы получаем 160 000 признаков. Одним из способов решения подобной проблемы, является непосредственное уменьшение алфавита аминокислот, объединяя их в группы со схожими свойствами [99]. Такое допущение снижает мощность алфавита и позволяет использовать увеличенные значения k, при этом оставляя возможность улавливать функционально значимые паттерны. Также существуют методы которые уменьшают итоговое пространство k-меров, например, учет зеркальной сим-

[6] K-мер — подпоследовательность длины k, полученная из исходной биологической последовательности; используется как структурная единица при анализе последовательностей.

[7] «Мешок слов» (Bag-of-Words, BoW) — метод представления последовательности в виде набора признаков, основанный на частоте встречаемости элементов без учёта их порядка.

[8] TF-IDF (Term Frequency – Inverse Document Frequency) — статистическая мера, используемая для оценки значимости элемента в последовательности относительно набора последовательностей на основе частоты его встречаемости.

метрии, при котором соответствующие подпоследовательности рассматриваются как один признак [84].

1.2.4. Контекстуальные векторные представления

Все вышеупомянутые подходы к кодированию биологических последовательностей в явном виде не могут учитывать контекст. Под контекстом подразумевается совокупность зависимостей между структурными единицам, которая включает как их поряд, таки и влияние этого порядка на итоговые векторные представления. Такой контекст отражает не только локальное окружение элемента, но и более сложные взаимодействия, которые влияют на формирование вторичной и третичной структуры. Таким образом, игнорирование контекста приводит к потере существенной части информации о всей последовательности.

Методы распределенных векторных представлений[9] теоретически позволяют учитывать контекст за счет обучения на основе совместной встречаемости элементов. Однако они не получили широкого распространения, так как данные методы опираются на многообразие структурных единиц в словаре, в то время как канонических аминокислот насчитывается двадцать единиц, а нуклеиновых кислот всего четыре.

Однако, более эффективный учет контекста возможен благодаря нейросетевым архитектурам. В частности, когда речь заходит о контексте, первыми на рассмотрение приходят рекуррентные нейронные сети с долговременной краткосрочной памятью (LSTM[10]). Особенностью такого вида архитектур является способность охватывать дальние зависимости между элементами за счет внутреннего состояния, которое накапливает информацию о предыдущих позициях. Ранние работы с использованием LSTM продемонстрировали удовлетворительные результаты в задачах предсказания свойств белков и нуклеиновых кислот. Наиболее известными моделями с подобной архитектурой являются UniRep [111] и Seqvec [60]. Модель Seqvec была создана для узкоспециализированной задачи идентификации некодирующих последовательностей ДНК, которые являются регуляторами транскрипционных процессов. В свою

[9]Распределенные векторные представления (word embeddings) — метод представления объектов в виде плотных векторов в непрерывном пространстве, обучаемых на основе контекстной совместной встречаемости элементов, обеспечивающий близость векторных представлений семантически сходных объектов.

[10]LSTM (Long Short-Term Memory) — тип рекуррентной нейронной сети, использующий специальный механизм для управления потоком информации, который позволяет эффективно моделировать долгосрочные зависимости в последовательных данных.

очередь авторы UniRep изначально позиционировали модель как инструмент для извлечения признаков из последовательности белка. Обучение здесь было основано на задаче предсказания следующего элемента последовательности, что соответствует парадигме авторегрессионного моделирования, широко используемой в современной обработке естественного языка. В результате модель позволяет описывать белковую последовательность вектором скрытых состояний фиксированной длины, который содержит информацию о контексте на разных уровнях.

В связи с тем, что биологические последовательности естественным образом описываются матрицей, где каждой позиции соответствует векторное описание аминокислоты или нуклеотида, возникает возможность применения сверточных архитектур. Характерным примером является модель DeepCAPE [31], которая показала высокую эффективность в задаче несбалансированной классификации энхансеров. Авторы отмечаю высокую специфичность модели к различным клеточным линиям, а через визуализацию ядра первого сверточного слоя показывают соответствие идентифицированных сигнатур последовательностей с известными мотивам, что является интересным подходом к интерпретации модели.

Среди подобных методов, использующих глубокие нейронные сети, стоит выделить DeepAffinity [30]. Данная модель служит для предсказания целевых точек связывания белка с малой молекулой. Архитектурно она реализована в виде автокодировщика[11], что позволяет обучать компактные латентные представления. В отличие от предыдущих представителей, которые опираются исключительно на кодирование самой последовательности белка, данная модель играет на интерпретируемости и дополнительно использует информацию о вторичной структуре. Такой подход является интересным и естественным образом более информативным, поскольку вторичная структура напрямую влияет на аффинность связывания белков с малыми молекулами. Однако наличие дополнительного этапа в виде моделирования вторичной структуры само по себе является ресурсоемкой задачей.

Несмотря на то, что перечисленные модели хорошо справляются с поставленными первоначальными целями, которые решают конкретную специ-

[11] Автокодировщик (autoencoder) — тип нейронной сети, обучаемой на восстановление входных данных через промежуточное компактное латентное представление, используемое для извлечения сжатых признаков и нелинейного понижения размерности.

фическую задачу, важным наблюдением является то, что извлекаемые ими скрытые представления могут использоваться как универсальные признаки для последующего анализа. Однако, в связи с тем, что эти работы можно назвать ранними, качество этих представлений, как правило, сравнивалось с классическими методами кодирования, такими как one-hot представления или частоты k-меров, что отражает этап становления области. При этом комплексных сравнительные исследования подобных архитектур проводились ограниченно. В основном это связано с тем, что на их смену стремительно пришли трансформерные модели, которые благодаря механизму внимания начали демонстрировать передовые результаты в задачах анализа биологических последовательностей широкого назначения [83].

1.3. Языковые модели белков

Белки являются центральными функциональными элементами в живых системах, которые обеспечивают такие важные функции как каталитическую активность, структурную организацию клеток и регуляцию биологических процессов. Понимание этих функций лежит в основе фундаментальных исследований в области молекулярной биологии и имеет критическое значение для прикладных задач, включая изучение механизмов заболеваний и разработку лекарственных препаратов [15]. Несмотря на значительный прогресс экспериментальных методов, таких как кристаллография, масс-спектрометрия и методы функционального скрининга, их применение по-прежнему связано с высокими затратами времени и ресурсов, а также ограниченной масштабируемостью [109].

За последние годы наблюдается рост объемов доступных биологических данных, особенно белковых последовательностей. Однако, очень малая доля из представленных белков имеет экспериментально подтвержденные и стандартизированные функциональные аннотации [113]. Это приводит к значительному разрыву между накоплением данных и их интерпретацией, что подчеркивает необходимость разработки автоматизированных методов анализа и аннотирования белков.

После внедрения архитектуры трансформеров языковые модели белков стали играть важную роль во многих задачах биоинформатики. Самым распространенным их применением является предсказание функции и свойств белков [67]. Кроме того, их архитектуры либо изначально имеют возможность

генерировать новые белковые последовательности, либо могут быть косвенно интегрированы в этот процесс. Смешанные подходы, основанные на контрастивном обучении[12] и обучении с подкреплением[13], помогают открывать новые белки с заранее заданными свойствами [68].

Предобученные языковые модели белков, такие как ESM [20], ProtBERT и ProtT5 [95], обучаются на огромных массивах немаркированных последовательностей с использованием механизма самообучения. В процессе обучения такие модели извлекают вектоные представления (далее — эмбеддинги[14]) в виде компактных числовых описаний белковых последовательностей, в которых потенциально могут быть неявно закодированы структурные, эволюционные и функциональные характеристики. В отличие от частотных признаков или выравниваний, эмбеддинги формируются автоматически и способны обобщать информацию даже для ранее не изученных белков. Более того, использование эмбеддингов позволяет существенно снизить зависимость от дорогостоящих множественных выравниваний последовательностей, сохраняя при этом высокую точность предсказаний [95].

Таким образом, языковые модели белков представляют собой мощный и перспективный класс методов с широким спектром применения. Их развитие открывает новые горизонты в биоинформатике, молекулярной биологии и смежных областях, делая автоматизированный анализ белков более масштабируемым и доступным.

1.3.1. Архитектуры моделей

Практически все распространенные языковые модели белков существенно различаются по своей архитектуре, стратегиям обучения и способам представления последовательностей. Эти различия во многом определяют их эффективность в задачах предсказания структуры, функций и свойств белков.

Модель ProtBert [95] представляет собой одну из первых масштабных попыток адаптации архитектуры трансформеров для анализа белковых по-

[12]Контрастивное обучение — это метод машинного обучения, при котором модель обучается различать схожие и несхожие объекты, минимизируя расстояние между представлениями похожих примеров и увеличивая его для различных.

[13]Обучение с подкреплением — это метод, при котором модель обучается принимать решения, взаимодействуя со средой и получая сигнал вознаграждения за желаемое поведение, что позволяет оптимизировать последовательность действий.

[14]Эмбеддинги — это векторные представления объектов (например, слов или биологических последовательностей) в непрерывном числовом пространстве, получаемые в процессе обучения модели и отражающие их семантические, структурные или функциональные свойства.

следовательностей. В ее основе лежит модель BERT (Bidirectional Encoder Representations from Transformers) [18], которая реализует многослойный двунаправленный трансформер-энкодер с механизмом self-attention[15]. Ключевое свойство данной архитектуры заключается в способности учитывать контекст каждого токена одновременно слева и справа, что особенно важно при работе с белками, где функциональные и структурные зависимости могут быть распределены по всей последовательности.

Адаптация BERT к белковым данным была выполнена посредством дополнительного обучения на крупных белковых базах данных, таких как UniRef100 [115] и Big Fantastic Database (BFD) [46], содержащих миллиарды аминокислотных остатков. Модель обучалась с использованием задачи маскированного языкового моделирования, при которой случайные 15% токенов скрываются, а модель должна их восстановить.

Входные последовательности были закодированы на уровне отдельных аминокислот, включая 20 стандартных символов и дополнительный токен для неизвестных остатков. Каждому токену был сопоставлен эмбеддинг с добавлением позиционного кодирования. Поскольку стандартный BERT ограничен фиксированной длиной входа, обучение ProtBert проводилось поэтапно с увеличением максимальной длины последовательности — от 512 до 1024 и далее до значительно больших значений, достигающих десятков тысяч токенов.

Ключевым преимуществом ProtBert является использование двунаправленного контекста, что позволяет эффективно захватывать глобальные зависимости в последовательностях. При этом было показано, что дальнейшее увеличение объема обучающих данных приводит лишь к незначительному улучшению качества, что может свидетельствовать о достижении определенного уровня насыщения модели.

Модель ProtT5 основана на архитектуре T5 (Text-to-Text Transfer Transformer), изначально разработанной как универсальный подход «вход–выход» для решения широкого круга задач обработки текста [38]. В отличие от более простых архитектур, данная модель включает два основных компонента

[15] Self-attention — это механизм, при котором для каждого элемента входной последовательности формируется новое представление как взвешенная сумма представлений всех элементов последовательности, где веса определяются степенью их взаимной релевантности.

— кодировщик[16] и декодировщик[17]. Однако при работе с белковыми последовательностями используется только кодировщик, что позволяет существенно снизить вычислительную сложность без заметного ухудшения качества формируемых представлений.

Обучение ProtT5 осуществлялось в два этапа, на первом из которых использовалась масштабная и зашумлённая база BFD, а на втором — более качественный набор UniRef50 [115]. Такой подход обеспечил улучшение обобщающей способности модели. Дополнительно применялась динамическая маскировка токенов, благодаря чему модель сталкивается с различными вариантами входных данных на каждой итерации. В совокупности эти решения позволили ProtT5 достичь высоких результатов в задачах предсказания структуры и функций белков, впервые продемонстрировав конкурентоспособность подходов без использования множественного выравнивания последовательностей [95].

Семейство моделей ESM (Evolutionary Scale Modeling) представляет собой одну из наиболее влиятельных линий развития языковых моделей белков, ориентированную на масштабирование трансформерных архитектур и извлечение универсальных представлений белковых последовательностей [20]. В основе моделей лежит двунаправленный трансформер-кодировщик, аналогичный BERT. Обучение моделей на белковых данных включало использование ограниченного словаря аминокислот и позиционного кодирования, а также масштабирование моделей от миллионов до десятков миллиардов параметров. В частности, ESM-2 была представлена в нескольких вариантах — от компактных до моделей с 15 миллиардами параметров. При этом все представители были обучены на одном и том же корпусе UniRef [115]. Это позволило продемонстрировать эффект масштабирования: увеличение числа параметров улучшает качество эмбеддингов, хотя со временем наблюдается эффект насыщения. Получаемые представления широко применяются в задачах предсказания вторичной структуры, контактов остатков, эффектов мутаций и функциональной аннотации, часто без необходимости использования множественного выравнивания последовательностей.

[16]Кодировщик — это часть нейронной сети, преобразующая входную последовательность в набор векторных представлений, отражающих её структуру и контекстные зависимости.

[17]Декодировщик — это компонент модели, который на основе представлений, полученных кодировщиком, генерирует выходную последовательность, учитывая ранее сгенерированные элементы.

Новейшая модель семейства ESM-C (ESM Cambrian) смещает фокус с простого увеличения размеров на повышение эффективности обучения и качества используемых данных. В отличие от ESM-2, она обучалась на существенно более разнообразных корпусах, включая метагеномные последовательности, и применяет усовершенствованные стратегии обучения, такие как динамическое маскирование[18] и более длительное расписание оптимизации[19]. Это позволяет моделям меньшего размера, например, порядка 600 миллионов обучаемых параметров, достигать результатов, сопоставимых с существенно более крупными моделями предыдущего поколения, где количество обучаемых параметров варьировалось от одного до трех миллиардов параметров.

Семейство моделей Ankh[20] [9] представляет собой развитие идей архитектуры автокодировщиков в контексте языкового моделирования белков и аналогична архитектуре T5. В отличие от ESM и ProtBert, где используется исключительно кодировщик, Ankh реализует полную схему «кодировщик–декодировщик», адаптированную для работы с аминокислотными последовательностями. Адаптация архитектуры к белковым данным включает стандартную токенизацию на уровне аминокислот, а также использование относительных позиционных эмбеддингов, что позволяет модели устойчиво обрабатывать последовательности, длина которых может превышать диапазон, наблюдаемый в обучении. Такой подход снижает чувствительность модели к абсолютной длине входа и улучшает обобщающую способность на длинных белках и доменных комбинациях.

В процессе обучения Ankh используется маскированное языковое моделирование с рядом модификаций. В частности, применяется более высокая доля маскирования токенов (около 20%), а также стратегия частичного демаскирования, при которой часть исходной информации сохраняется в явном виде на ранних этапах обучения. Это способствует более стабильной сходимости и улучшает качество восстановленных представлений. Дополнительно исполь-

[18]Динамическое маскирование — стратегия обучения, при которой маскируемые элементы входной последовательности переопределяются на каждой итерации, что увеличивает разнообразие обучающих примеров и способствует лучшему обобщению модели.

[19]Длительное расписание оптимизации — схема организации процесса обучения, при которой изменение параметров оптимизации распределяется на большее число шагов, обеспечивая более стабильную сходимость и повышение качества итоговой модели.

[20]Семейство названо в честь древнеегипетского символа «анкх» — «ключа жизни», отражая идею о том, что модель позволяет «открывать» язык жизни.

зуются архитектурные улучшения, включая активацию Gated-GELU[21], которая повышает выразительность нелинейных преобразований при относительно компактном числе параметров.

Обучение моделей Ankh проводилось на корпусе UniRef50 [115]. Полученные представления демонстрируют высокую эффективность в задачах предсказания вторичной структуры, функциональной аннотации белков, а также оценки эффектов мутаций. При этом важной особенностью Ankh является сочетание сравнительно небольшого числа параметров с высокой качественной производительностью, что позволяет моделям конкурировать с более крупными архитектурами, включая ESM-2.

Различные версии Ankh отличаются главным образом масштабом архитектуры, включая размер скрытых представлений и число attention-голов. Увеличение этих параметров приводит к стабильному росту качества эмбеддингов, однако при этом сохраняется общая архитектурная схема и характер обучения. В результате Ankh представляет собой семейство моделей, позволяющее гибко балансировать между вычислительными затратами и точностью представлений в зависимости от целевой задачи.

1.4. Существующие методы сравнения векторных представлений

Вслед за обзором архитектур белковых языковых моделей, ключевым этапом является анализ того, каким образом оценивается качество формируемых ими эмбеддингов. В современной литературе набрал популярность протокол сравнительного анализа, основанный на изолированной оценке эмбеддингов без дообучения самих языковых моделей.

В рамках таких бенчмаркингов задачи, как правило, делятся на две основные категории. Первая категория включает задачи, формулируемые на уровне отдельных аминокислотных остатков. Вторая категория охватывает задачи, рассматривающие белок как целостную последовательность. К первой группе прежде всего относится предсказание вторичной структуры белка в постановках Q3[22] и Q8[23], которое формулируется как задача многоклассовой

[21] Gated-GELU — модификация функции активации GELU, в которой выход дополняется элементом «гейтинга» (управляющего множителя).

[22] Q3 — постановка задачи предсказания вторичной структуры белка, в которой каждая аминокислота классифицируется на один из трёх классов: α-спираль (H), β-структура (E) или петли и прочие участки (C).

[23] Q8 — более детализированная постановка задачи предсказания вторичной структуры белка, в которой каждая аминокислота классифицируется на один из восьми классов вторичной структуры согласно DSSP-классификации.

классификации для каждой позиции последовательности. Ко второй группе относятся задачи, направленные на оценку свойств белка в целом. Сюда входит, в частности, предсказание субклеточной локализации, рассматриваемое как многоклассовая классификация, а также задачи бинарной классификации, например различение мембранных и растворимых белков.

В работах, посвящённых сравнительному анализу белковых языковых моделей, такие задачи используются в качестве одного из основных бенчмарков для оценки качества представлений. В частности, в исследовании ProtTrans при сравнении различных подходов рассматривался широкий спектр методов, охватывающий как классические, так и современные архитектуры.

Особое место в сравнительном анализе белковых языковых моделей занимают задачи бинарной классификации, которые широко используются как в методологических бенчмарках, так и в прикладных биоинформатических задачах [78, 115]. В контексте биологических данных задачи бинарной классификации обладают рядом характерных особенностей. Для них обычно доступно больше аннотированных данных по сравнению с более сложными постановками, поскольку крупные базы данных, такие как UniProt, содержат большое количество аннотаций, которые естественным образом могут быть приведены к бинарному виду [112]. Это делает такие задачи особенно удобными для массового бенчмаркинга.

Дополнительной особенностью биологических данных является выраженная асимметрия классов: положительные примеры, как правило, основаны на экспериментально подтвержденных наблюдениях, тогда как отрицательные часто формируются искусственно, например из не аннотированных последовательностей [75].

Несмотря на возможный шум в отрицательном классе, бинарные задачи остаются относительно надежными, поскольку положительные примеры обладают высокой степенью достоверности. Это делает такие постановки устойчивыми для оценки качества моделей по сравнению с многоклассовыми или регрессионными задачами [36].

1.5. Ограничения методов сравнений

Несмотря на значительный прогресс в разработке белковых языковых моделей, подходы к их сравнительному анализу остаются ограниченными и не всегда отражают реальное качество эмбеддингов. Одной из ключевых про-

блем является отсутствие стандартизации бенчмарков. В разных исследованиях используются отличающиеся наборы данных, задачи и протоколы оценки, что затрудняет корректное сопоставление результатов. Так, в рамках бенчмарка TAPE [36] предлагается фиксированный набор из пяти задач, включающий структурные и функциональные предсказания, тогда как в работах, посвященных моделям ProtBert и ProtT5, применяются иные датасеты и постановки. Это связано с тем, что единый универсальный бенчмарк до сих пор не сформирован, а выбор задач во многом определяется целями конкретной модели. В результате наблюдаемые различия в качестве моделей часто оказываются неотделимыми от различий в используемых данных и экспериментальных протоколах.

Не менее важным ограничением является способ агрегирования результатов. В большинстве работ итоговая оценка модели формируется путем усреднения метрик по нескольким задачам или датасетам. При этом не учитывается, что эти задачи могут существенно различаться по сложности. На практике одни датасеты могут содержать хорошо разделимые классы и давать заведомо более высокие результаты, тогда как другие характеризуются шумом, дисбалансом классов или высокой степенью перекрытия распределений. Проблема усугубляется неоднородностью самих данных. Наборы, используемые в бенчмаркинге, могут различаться по уровню гомологии последовательностей, качеству аннотаций и степени зашумленности. Это напрямую влияет на сложность задач и, как следствие, на итоговые метрики моделей. Тем не менее, в стандартных протоколах такие различия, как правило, не учитываются, и все задачи рассматриваются как равнозначные. Это приводит к систематическому смещению итоговых оценок, при котором результаты моделей в большей степени отражают особенности используемых датасетов, чем их реальную способность обобщать на более сложные и разнообразные данные. Это указывает на необходимость более аккуратного подхода к сравнительному анализу, учитывающего различия между задачами и используемыми наборами данных.

Выводы по главе 1

ГЛАВА 2. РАЗРАБОТКА МЕТОДА СРАВНИТЕЛЬНОГО АНАЛИЗА ВЕКТОРНЫХ ПРЕДСТАВЛЕНИЙ

2.1. Методы измерения сложности наборов данных

В последние годы задача оценки сложности наборов данных и соответствующих задач классификации приобретает всё большую актуальность в машинном обучении. Это связано с необходимостью не только повышать качество моделей, но и лучше понимать природу самих данных, с которыми они работают. Большинство существующих исследований в данной области, направлены на интерпретацию структуры данных через совокупность количественных характеристик, позволяющих выявить факторы, влияющие на трудность классификации [48, 49]. Анализ сложности, основанный на сочетании интерпретируемых характеристик данных и эмпирических оценок производительности моделей, представляет собой важный инструмент исследования задач классификации. Данный подход способствует более глубокому пониманию взаимосвязи между свойствами данных и поведением алгоритмов, а также позволяет выявлять ограничения применимости различных методов.

Практика использования качества работы базовых моделей в качестве прокси-оценки[1] сложности задачи получила распространение в литературе [22]. Использование метрик, таких как макро-F1, усредненных по набору различных алгоритмов, является обоснованным, поскольку такие показатели напрямую отражают эмпирическую трудность задачи. Ситуации, когда широкий класс моделей демонстрирует низкое качество, свидетельствуют о высокой сложности данных. Одновременно агрегирование результатов по нескольким моделям снижает зависимость оценки от конкретного алгоритма и обеспечивает более устойчивую характеристику.

2.1.1. Сложность задач классификации табличных данных

В ранних работах, затрагивающих тему установления сложности задачи через анализ данных, рассматриваются задачи количественного описания сложности классификации с учителем на табличных данных [48, 49]. Сложность в них трактовалась как совокупность факторов, затрудняющих достижение наименьшей байесовской ошибки. К основным источникам были отнесены перекрытие классов, шум измерений, сложная геометрия границы ре-

[1]Прокси-оценка — косвенная оценка, при которой интересующая величина (в данном случае сложность задачи) измеряется через наблюдаемую связанную характеристику.

шений, а также малый объем выборки при высокой размерности пространства признаков. Центральное внимание уделялось сложности дискриминации, определяемой геометрией оптимальной границы.

Было установлено, что использование только одного показателя не позволяет адекватно описать свойства задачи. Поэтому было принято решение ввести пространство признаков сложности, в котором каждая задача представляется точкой. Положение в этом пространстве отражает характер трудности задачи и позволяет сопоставлять ее с областями эффективной работы различных классификаторов.

В таких работах принято разбивать набор показателей на группы, описывающих разные аспекты структуры данных. Например, характеристики перекрытия признаков включают дискриминантное отношение Фишера, объем перекрытия и эффективность признаков, оцениваемую долю объектов, разделимых последовательным отбором признаков. Линейная разделимость описывается показателями, основанными на линейных моделях. Также присутствуют меры, описывающие геометрию распределений через меры соседства и взаимного расположения объектов разных классов.

Было показано, что меры нелинейности могут отражаться показателями, использующими интерполяцию между объектами одного класса. Дополнительно были сформированы характеристики покрытия пространства и соотношения числа объектов и размерности. Для анализа совокупности показателей формируется пространство сложности, к которому применяется метод главных компонент. Это позволило выявить структуру задач и вклад отдельных характеристик. Однако подход не дал единого скалярного показателя сложности, а интерпретация осуществлялась через положение задачи в пространстве признаков.

Для текущей работы из рассмотренных подходов представляют интерес лишь отдельные группы метрик, которые могут быть перенесены на биологические последовательности и задачи, основанные на них. В частности, релевантными оказываются показатели, связанные с дисбалансом классов и графовыми характеристиками, поскольку они слабо зависят от конкретного способа представления данных и лучше сохраняют интерпретируемость в неклассических пространствах признаков.

Так как большинство исходных мер предполагает табличное представление данных, в работе используется разреженное кодирование последовательностей. Такой способ позволяет одновременно сохранить информацию о составе и порядке аминокислот, что важно для биологических последовательностей, где структура имеет принципиальное значение. В этой постановке ряд показателей, связанных, например, с соотношением числа объектов и размерности пространства, теряет содержательный смысл, поскольку искусственно индуцированная размерность не отражает реальную сложность задачи.

Дополнительно в рамках предлагаемого подхода используется понятие эмпирической сложности, основанной на качестве работы базовых моделей. Сложность задачи оценивается через производительность нескольких классификаторов, что позволяет рассматривать ее как функцию достижимой точности в фиксированном наборе алгоритмов. В качестве базовых моделей используются методы различной природы, включая линейные модели и методы ближайших соседей. В связи с этим показатели, описывающие линейную разделимость, геометрию распределений и эффективность признаков, оказываются частично избыточными, поскольку аналогичная информация уже отражается в результатах работы используемых базовых моделей. По этой причине данные группы признаков исключаются из дальнейшего рассмотрения, чтобы избежать дублирования информации и смещения оценки сложности в сторону конкретных алгоритмов.

По итогу, в данной работе были использованы такие характеристики, как энтропия классовых долей, сложность локального множества, коэффициент кластеризации, плотность графа в пространстве признаков, а также покрытие пространства гиперсферами. Их перечисление и условные обозначения представлены в таблице 1.

Таблица 1 – Набор используемых метрик для оценки сложности классификационных задач.

Название	**Условное обозначение**
Энтропия классовых долей	C1
Доля гиперсфер, покрывающих данные	T1
Мера коэффициента кластеризации	density
Мера плотности	clsCoef

Энтропия классовых долей используется для количественного описания баланса классов в выборке и отражает степень неопределенности априорного распределения. Данный показатель вычисляется на основе относительных частот классов и соответствует классической мере Шеннона. При равномерном распределении объектов между классами энтропия достигает максимального значения, что указывает на отсутствие доминирующего класса и потенциально более высокую неопределенность задачи. Напротив, при выраженном дисбалансе классов значение энтропии снижается, что отражает структурную асимметрию данных и может влиять на смещение моделей в сторону преобладающего класса.

Сложность локального множества отражает локальную структуру соседства объектов и степень перекрытия классов в окрестностях отдельных наблюдений. Для каждого объекта формируется локальное множество, включающее все точки, расположенные ближе к нему, чем его ближайший объект из другого класса. Размеры таких множеств вычисляются для всех объектов выборки, после чего агрегируются в итоговую характеристику с нормировкой на квадрат числа наблюдений. Высокие значения этой меры соответствуют ситуациям, в которых локальные множества малы, что свидетельствует о сильном перекрытии классов и высокой неоднозначности локальных областей принятия решений. Напротив, низкие значения указывают на более выраженную локальную разделимость классов.

Показатель покрытия пространства гиперсферами основан на геометрическом представлении выборки через систему гиперсфер, покрывающих пространство объектов. Для каждого наблюдения формируется гиперсфера с центром в соответствующей точке, радиус которой определяется расстоянием до ближайшего объекта другого класса. Затем выполняется процедура исключения избыточных гиперсфер: начиная с гиперсфер максимального радиуса, удаляются те, центр которых уже покрыт гиперсферой большего или равного радиуса. Итоговое значение метрики определяется как доля оставшихся гиперсфер, необходимых для покрытия всей выборки. Данный показатель отражает степень компактности представления данных и связан с возможностью аппроксимации структуры классов ограниченным числом локальных областей без конфликтов. Высокие значения этого показателя указывают на необходи-

мость большого числа неперекрывающихся локальных областей, что свидетельствует о сложной геометрии разделения классов.

Коэффициент кластеризации характеризует выраженность локальной структурированности данных в графовом представлении. Для каждого объекта определяется его окрестность в виде множества соседних вершин, связанных с ним в графе близости. Далее оценивается количество ребер между всеми парами соседей данного объекта и нормируется на максимально возможное число таких ребер. Полученное значение интерпретируется как локальная плотность связей внутри окрестности узла и вычисляется для всех объектов выборки с последующим усреднением. Высокие значения соответствуют хорошо выраженной внутриклассовой кластеризации, при которой соседи объектов с высокой вероятностью также связаны между собой. Низкие значения указывают на разреженную и слабо структурированную локальную организацию данных, что может свидетельствовать о сложной и неоднородной структуре классов.

Плотность графа отражает общую степень связности пространства признаков и определяется как отношение фактического числа ребер в графе к максимально возможному числу ребер между всеми парами объектов. В отличие от локальных характеристик, данный показатель является глобальной метрикой и описывает общую «насыщенность» пространствами. Высокая плотность соответствует ситуации, в которой большинство объектов находится в близком соседстве друг с другом, что может указывать на сильное перекрытие классов и слабую выраженность структурных разрывов. Низкие значения плотности, напротив, отражают разреженность графа и потенциально более выраженную геометрическую разделимость данных.

Совместное использование данных характеристик позволяет охватить как глобальные свойства распределения классов, так и локальные эффекты перекрытия и структурной неоднородности. Это обеспечивает согласование с эмпирической оценкой сложности, основанной на качестве работы базовых моделей и измеряемой через МСС, при сохранении интерпретируемости и устойчивости к выбранному способу кодирования последовательностей.

2.1.2. Сложность задач классификации текстовых данных

В отличие от работ, ориентированных на табличные данные, задачи обработки естественного языка требуют учета специфики текстов, включая лексическое разнообразие, статистику n-грамм и распределение символов. В ряде

исследований предлагается формировать единый скалярный показатель сложности текстовых наборов данных [22].

Цель подхода заключалась в получении интерпретируемой количественной оценки сложности, связанной с качеством классификации. В качестве эталона сложности использовалось качество классификации, измеряемое макро-F1[2]. Для повышения надежности применялся ансамбль из двенадцати моделей, включающий классические методы машинного обучения и простые нейросетевые архитектуры. Векторные представления текстов строились с помощью TF–IDF и символьного кодирования. Наборы данных в основном относятся к многоклассовой классификации коротких текстов длиной до ста слов.

Описание сложности было основано на 48 статистических показателях. Они отражали разнообразие и баланс классов, степень их взаимного влияния через сходство распределений n-грамм, а также общие свойства данных, включая долю уникальных n-грамм, читаемость и характеристики распределений символов и n-грамм.

Итоговый показатель формировался с использованием генетического алгоритма, выполняющего отбор признаков. Полученный показатель продемонстрировал высокую отрицательную корреляцию Пирсона с макро-F1, что подтверждает его информативность. В работах подчеркивается важная роль лингвистически обоснованных метрик, включая индекс читаемости Флеша и сходные показатели. Однако, их применение требует осторожности, особенно в многоклассовых задачах, где возможна потеря различительной способности. В целом эффективная оценка сложности текстовых данных предполагает совместный учет статистических и лингвистических характеристик с их интеграцией в единый показатель.

Для настоящей работы из рассмотренного подхода наибольший интерес представляет методология установления связи между итоговой оценкой сложности и качеством классификации. Сам набор метрик, применяемый для измерения сложности текстовых данных, не обладает высокой информативностью в контексте биологических последовательностей, поскольку их структура не подчиняется лингвистическим закономерностям. В случае биологических данных более значимыми оказываются показатели, основанные на иного

[2]Макро-F1 — усредненная по классам F1-мера, которая вычисляется как среднее арифметическое значений F1 для каждого класса

рода статистических и структурных свойствах, которые отражают особенности последовательностей и их внутреннюю организацию.

2.1.3. Характеристики разнообразия аминокислотных последовательностей

Помимо геометрических и структурных метрик сложности классификации, важную роль в описании пептидных датасетов играют характеристики, отражающие внутреннее разнообразие самих аминокислотных последовательностей. Эти признаки позволяют оценить, насколько неоднородны биологические данные на уровне первичной структуры[3], и дополняют представление о сложности задачи информационными и статистическими свойствами последовательностей.

Одной из базовых характеристик является энтропия распределения аминокислот в последовательности. Она вычисляется на основе частот встречаемости 20 стандартных аминокислот и отражает степень неопределенности или разнообразия символов в белковой цепи. С точки зрения теории информации, энтропия позволяет количественно оценить, насколько предсказуемым является символический процесс формирования белковой цепи. Ранее было показано, что энтропия последовательностей внутри белковых доменов ниже, чем в естественных языках, например английском, но при этом существенно отличается от случайного равномерного распределения символов, что указывает на наличие биологических ограничений и структурных закономерностей в формировании белков [40].

В контексте данной работы энтропия используется как индикатор вариативности аминокислотного состава, так как низким значениям соответствуют доменно-специфичным, консервативным последовательностям, тогда как высокие значения характерны для более разнообразных и менее структурированных наборов пептидов.

Не менее показательной характеристикой является длина аминокислотной последовательности которая определяет сложность биологического объекта. Белки демонстрируют крайне широкий диапазон длин, охватывающий несколько порядков величины: от коротких пептидов и гормонов длиной менее 20 аминокислот до крупных структурных белков, содержащих десятки тысяч

[3]Первичная структура — это линейная последовательность аминокислотных остатков в полипептидной цепи белка или пептида.

аминокислот. Такой диапазон наблюдается во всех таксономических группах, от вирусов до человека, что отражает фундаментальную универсальность белковых молекул и разнообразие их биологических функций [114].

Для данной работы длина последовательности имеет значение как фактор, влияющий на сложность задачи классификации, поскольку увеличение длины приводит к росту числа возможных комбинаций аминокислот и, соответственно, к расширению пространства поиска для моделей машинного обучения. Кроме того, длинные последовательности чаще содержат несколько функциональных доменов, что увеличивает внутриклассовую вариативность.

Для оценки структурного разнообразия последовательностей в наборе данных становится актуальным использование метрики попарного расстояния Левенштейна, которая определяет минимальное число операций вставки, удаления и замены, необходимых для преобразования одной аминокислотной последовательности в другую.

Попарное расстояние Левенштейна, впервые введенное в контексте теории кодирования [1], является классической мерой различия строк и широко используется для сравнения биологических последовательностей. В дальнейшем оно было формализовано в рамках макромолекулярной теории последовательностей [66] и рассматривается как базовая метрика в задачах выравнивания белков [17].

Высокие значения данного показателя указывают на сильную гетерогенность данных, что может усложнять обучение классификаторов из-за отсутствия устойчивых локальных паттернов. Напротив, низкие значения расстояний свидетельствуют о наличии кластеризованной структуры, где последовательности внутри классов обладают высокой степенью сходства. В связи с этим, метрика попарных расстояний Левенштейна призвана отражать глобальную вариативность пространства последовательностей и является важным индикатором сложности выравнивания и сопоставления биологических объектов.

Еще одной характеристикой разнообразия является число уникальных тримеров[4] аминокислот, встречающихся в последовательностях. Данный показатель призван отражать локальную комбинаторную сложность и богатство последовательностных паттернов.

[4]Триме́ры — это частный случай k-меров при значении k, равном трем.

Представление последовательностей через k-mer статистики является стандартным подходом в методах биоинформатики, не требующие выравнивания. Ранние работы показали, что частоты подпоследовательностей фиксированной длины эффективно отражают функциональные и эволюционные сигналы [117], что сделало их базовым инструментом для численной характеристики биологических последовательностей [97].

Для коротких биологических последовательностей, таких как пептиды, использование длинных k-меров приводит к высокой разреженности статистики и снижению надежности оценок частот, в то время как тримеры обеспечивают устойчивые статистические характеристики даже на ограниченных выборках, что делает их предпочтительными для анализа пептидных датасетов. При этом тримеры представляют собой разумный компромисс между информативностью и размерностью признакового пространства. С биологической точки зрения они отражают локальные аминокислотные контексты минимальной длины, достаточной для частичного описания структурных и функциональных мотивов белков. Также многие элементы вторичной структуры и сайты взаимодействия определяются короткими паттернами, что делает тримеры естественной и интерпретируемой единицей анализа.

Высокое число уникальных тримеров свидетельствует о большом разнообразии локальных структур и слабой повторяемости мотивов, что затрудняет обобщение моделей. Напротив, ограниченное число тримеров может указывать на наличие консервативных мотивов или доменной специфичности, что потенциально упрощает задачу классификации.

Дополнительно был введен признак, который представляет из себя нормированное число уникальных тримеров нормированное на общее число всех возможных тримеров в последовательности. Такой показатель позволяет получить масштабно-инвариантную оценку разнообразия локальных паттернов, не зависящую от длины последовательности, и показывает степень насыщенности последовательности различными комбинациями аминокислот. Так высокие значения соответствуют более равномерному и разнообразному наличию комбинаций, а низкие указывают на повторяемость и наличие консервативных мотивов. В результате данный признак дополняет абсолютное число уникальных тримеров, устраняя влияние размера последовательности и повышая интерпретируемость оценки структурного разнообразия.

Для каждого из описанных признаков (энтропия, длина, расстояния Левенштейна и число уникальных тримеров) в рамках каждого набора данных вычисляются статистические агрегаты: среднее значение, медиана, минимум, максимум и стандартное отклонение. Такой подход позволяет не только учитывать центральную тенденцию распределения, но и фиксировать его асимметрию и вариативность.

Использование набора агрегатов особенно важно в биологических данных, где распределения часто являются скошенными и содержат выбросы. В совокупности данные признаки формируют многомерное описание разнообразия последовательностей, которое дополняет метрики сложности классификации и позволяет более полно характеризовать пептидные датасеты.

2.2. Базовая сложность набора данных

В данной работе вводится понятие базовой эмпирической сложности набора данных, которое используется как референсная характеристика для последующего анализа признаков и группировки наборов по уровню трудности. Под базовой сложностью понимается совокупная способность стандартных классификаторов извлекать устойчивую разделяющую структуру из данных при фиксированном представлении признаков. Интуитивно, чем менее выражены закономерности в данных и чем выше степень перекрытия классов, тем ниже ожидаемое качество классификации при использовании большого спектра моделей. Такой подход согласуется с рядом работ, в которых сложность задачи классификации оценивается через производительность ансамбля моделей citecollins2018evolutionary.

Также сложность наборов данных в задачах отбора признаков продемонстрировала свою значимость [35]. Здесь сложность определяется через усредненную производительность множества классификаторов, а также через категоризацию по AUC-ROC[5]. Подчеркивается, что использование ансамбля алгоритмов различной природы (линейные модели, маржинальные методы, ансамбли и непараметрические подходы) позволяет минимизировать зависимость оценки сложности от конкретной модели и тем самым приблизить ее к свойству самого набора данных, а не метода обучения.

[5] AUC-ROC (Area Under the Receiver Operating Characteristic Curve) — метрика качества бинарной классификации, отражающая способность модели различать классы при различных порогах принятия решения.

Перенимая практики на задачу оценки сложности данных включающих биологические последовательности, в работе используется ансамблевый подход к количественной оценке сложности. Для каждого набора данных формируется вектор качества, полученный с помощью пятикратной кросс-валидации[6]а группе классификаторов, представляющих различные семейства алгоритмов:

— обобщенные линейные модели;
— непараметрические методы;
— метод опорных векторов;
— ансамблевые алгоритмы.

Применение разнородных моделей позволяет учесть различия в индуктивных смещениях и тем самым охватить широкий спектр возможных структур данных. В совокупности это даёт возможность интерпретировать итоговую производительность как усредненную способность различных алгоритмических подходов выявлять закономерности в данных.

Для оценки качества классификаторов используются три стандартные метрики. В первую очередь рассматривается коэффициент корреляции Мэтьюса (MCC), который определяется следующим образом:

$$\text{MCC} = \frac{TP \cdot TN - FP \cdot FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}},$$

где TP — число истинно положительных объектов, TN — истинно отрицательных, FP — ложно положительных, FN — ложно отрицательных.

Дополнительно используется F1-мера как сбалансированная характеристика точности и полноты:

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall},$$

где $Precision = \frac{TP}{TP+FP}$ — точность, а $Recall = \frac{TP}{TP+FN}$ — полнота.

Наконец, учитывается метрика AUC-ROC, которая интерпретируется как площадь под ROC-кривой и может быть записана как вероятность корректного ранжирования:

$$\text{AUC} = P\big(s(x^+) > s(x^-)\big),$$

[6] н

где $s(x)$ — скоринговая функция модели, x^+ — случайный объект положительного класса, а x^- — случайный объект отрицательного класса.

В качестве основной меры для итогового ранжирования используется MCC, поскольку он устойчив к дисбалансу классов и учитывает все элементы матрицы ошибок, что особенно важно для биологических данных с асимметричным распределением классов.

Вместо выбора наилучшей модели используется усреднение результатов по всем алгоритмам и разбиениям кросс-валидации[7]. Полученная агрегированная величина отражает ожидаемую способность стандартных методов извлекать структуру из данных. Если разнородные модели демонстрируют стабильно низкое качество, это указывает на высокую сложность задачи, связанную с перекрытием классов или отсутствием устойчивых признаков. Напротив, согласованно высокие значения метрик свидетельствуют о наличии выраженной структуры.

Интерпретация использования производительности моделей в качестве меры сложности опирается на несколько соображений. Вначале заключается, что плохая разделимость классов в фиксированном признаковом пространстве приводит к снижению качества большинства алгоритмов независимо от их природы. В то же время усреднение по моделям снижает зависимость оценки от конкретного метода и позволяет рассматривать ее как свойство данных. Кроме того, эмпирическая производительность ансамбля может рассматриваться как приближение к нижней границе ошибки классификации, определяемой распределением классов. Существенную роль играет стабильность результатов, поскольку согласовано низкое качество отражает структурную неопределенность данных, тогда как высокая вариативность указывает на чувствительность к выбору модели.

Предложенный подход близок к идеям meta-learning[8] и анализа характеристик наборов данных, где поведение набора базовых моделей используется как представление задачи. В этом контексте важна не максимальная достижи-

[7]Кросс-валидация — метод оценки обобщающей способности модели, при котором исходные данные многократно разбиваются на обучающие и валидационные подвыборки, что позволяет получить более устойчивую и независимую от конкретного разбиения оценку качества.

[8]Meta-learning — направление машинного обучения, изучающее, как использовать опыт решения множества задач для повышения эффективности обучения на новых задачах, в том числе через анализ поведения моделей и извлечение обобщенных характеристик данных.

мая точность, а согласованность результатов разных алгоритмов на одном и том же распределении.

Искомая базовая сложность определяется как агрегированная производительность ансамбля разнородных классификаторов, обученных на фиксированном представлении аминокислотных последовательностей. Эта величина интерпретируется как эмпирическая мера трудности задачи классификации и далее используется как опорная характеристика для анализа признаков, изучения взаимосвязей и ранжирования наборов данных.

2.3. Кластеризация

В задаче анализа сложности биологических наборов данных возможны два подхода, основанные либо на предсказании непрерывного значения сложности, либо на выделении дискретных групп. В данной работе выбран второй подход, поскольку он обеспечивает более устойчивое и интерпретируемое представление структуры данных при ограниченном объеме доступных бенчмарков.

Построение регрессионной модели сложности требует наличия большого и репрезентативного набора данных, охватывающего широкий спектр распределений пептидных последовательностей и соответствующих значений сложности. Однако в реальных условиях количество независимых биологических данных ограничено, что делает обучение устойчивой регрессионной модели затруднительным и повышает риск переобучения. Дополнительной проблемой является то, что используемая в качестве базовой сложности метрика, основанная на качестве классификации простых моделей, обладает высокой вариативностью и зависит не только от внутренней структуры данных, но и от стохастических факторов обучения. Поэтому неизбежными будут условные смещения, которые будут не инвариантны к монотонным преобразованиям. Это приведет к тому, что непрерывная шкала сложности оказывается слабо интерпретируемой.

Однако, кластеризация позволяет перейти от задачи точного предсказания к задаче выявления устойчивых групп объектов с близкими структурными свойствами. В результате наборы данных объединяются в однородные по сложности и внутренней организации пространства признаков группы. Такой переход существенно снижает чувствительность к шуму в оценке сложности, поскольку вместо индивидуальных значений рассматриваются агрегиро-

ванные характеристики кластеров. Помимо этого, данный подход не требует большого объема размеченных данных и обеспечивает более устойчивую интерпретацию результатов за счет перехода к дискретным уровням сложности. Следовательно, кластеризация в данной постановке рассматривается как способ регуляризации пространства сложности и построения структурированного представления множества биологических задач.

Для группировки наборов данных в рамках работы рассматривались несколько методов кластеризации, отличающихся предположениями о геометрической структуре данных и механизмах формирования кластеров.

Одним из базовых методов кластеризации является k-means, который минимизирует внутрикластерную дисперсию и предполагает, что кластеры имеют компактную, близкую к сферической форму в пространстве признаков. Данный метод эффективен в случаях, когда группы объектов хорошо отделимы в евклидовом пространстве и имеют сопоставимую плотность. Однако он чувствителен к выбросам и масштабу признаков, а также требует априорного задания числа кластеров, что ограничивает его применимость при отсутствии информации о структуре данных.

Иерархическая агломеративная кластеризация, напротив, не требует предварительного задания числа кластеров и строит вложенную структуру объединения объектов, формируя дерево кластеров. Такой подход позволяет анализировать структуру данных на различных уровнях детализации и выявлять потенциальную иерархию сложности. Однако метод чувствителен к выбору метрики расстояния и критерия слияния кластеров, а также обладает ограниченной масштабируемостью.

Спектральная кластеризация основана на представлении данных в виде графа схожести и последующем переходе в пространство собственных векторов лапласиана графа. Такой подход позволяет выявлять нелинейные структуры разделения данных, которые не могут быть корректно описаны методами, основанными на евклидовой геометрии. Метод особенно эффективен в случаях сложной геометрии кластеров, однако требует тонкого выбора параметров для построения графа и чувствителен к плотности распределения точек, что может приводить к нестабильности при неоднородных данных.

Метод Density-Based Spatial Clustering of Applications with Noise (DBSCAN), основанный на плотностной кластеризации, группирует объек-

ты в зависимости от локальной плотности их распределения, выделяя области высокой концентрации и рассматривая разреженные области как шум. Его основным преимуществом является отсутствие необходимости задавать число кластеров и способность выявлять кластеры произвольной формы. Однако эффективность метода существенно зависит от выбора параметров плотности и ухудшается при неоднородной структуре плотностей в данных, что может быть характерно для биологических датасетов различной природы.

Для выбора оптимального метода кластеризации и определения числа кластеров использовалась совокупность критериев, отражающих как геометрические свойства разбиения, так и его согласованность с понятием базовой сложности.

В качестве стандартной метрики использовался silhouette score[9], который характеризует степень разделимости кластеров в пространстве признаков и позволяет оценить, насколько хорошо структура данных соответствует выбранному разбиению. Данная метрика определяется как

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}},$$

где $a(i)$ — среднее расстояние от объекта i до всех других объектов своего кластера, а $b(i)$ — минимальное среднее расстояние от объекта i до объектов ближайшего соседнего кластера. Значение $s(i)$ близкое к 1 соответствует хорошо отделимым кластерам, значение около 0 указывает на перекрытие кластеров, а отрицательные значения свидетельствуют о возможной ошибочной кластеризации.

Дополнительно был введен коэффициент разделения кластеров, ориентированный на согласование результатов кластеризации с последующим использованием кластеров в анализе сложности:

$$S = \frac{\min_{i \neq j} |\mu_i - \mu_j|}{\frac{1}{K} \sum_{k=1}^{K} \sigma_k^2},$$

где μ_k — среднее значение МСС в k-м кластере, σ_k^2 — дисперсия МСС внутри k-го кластера, а K — число кластеров. Числитель отражает минимальное

[9] Silhouette score оценивает степень разделимости кластеров на основе внутрикластерной компактности и межкластерного расстояния.

различие между кластерами по средним значениям сложности, а знаменатель характеризует среднюю внутрикластерную вариативность. Чем выше значение S, тем лучше разделены кластеры относительно их внутреннего разброса.

Данный критерий основан на сравнении средних значений базовой сложности внутри кластеров и оценке различий между ними относительно внутрикластерного разброса. Ключевым требованием является достижение ситуации, при которой различия между средними значениями сложности различных кластеров сопоставимы или превышают вариативность внутри самих кластеров. Это позволяет минимизировать перекрытие распределений сложности между кластерами и обеспечить устойчивость последующего ранжирования кластеров по уровню сложности.

Отдельно рассматривался коэффициент вариации размеров кластеров, который использовался как вспомогательная характеристика качества разбиения:

$$CV = \frac{\sigma_{|C|}}{\mu_{|C|} + \varepsilon},$$

где $\mu_{|C|}$ — средний размер кластеров, $\sigma_{|C|}$ — стандартное отклонение размеров кластеров, а ε — малая константа, предотвращающая деление на ноль. Чем ниже значение CV, тем более сбалансированы кластеры по размерам.

Хотя данный критерий не влияет напрямую на интерпретируемость сложности, сильный дисбаланс размеров кластеров может приводить к снижению статистической устойчивости оценок и доминированию отдельных групп при агрегировании результатов. В связи с этим баланс размеров кластеров учитывался как дополнительный ограничивающий фактор при выборе финальной конфигурации кластеризации.

Подводя итоги, задача кластеризации в данной работе рассматривается не как самостоятельная цель сегментации данных, а как этап построения структурированного пространства сложности биологических датасетов. Использование нескольких алгоритмов кластеризации в сочетании с многокритериальной оценкой качества позволяет повысить устойчивость искомого разбиения и снизить зависимость результатов от конкретного метода. В результате формируется стабильная группировка наборов данных, отражающая как геометрические свойства пространства признаков, так и их согласованность с эмпирической оценкой сложности, основанной на качестве классификации простых моделей.

2.4. Корректное сравнение векторных представлений

В рамках данной работы предлагается процедура, которая преобразует структурированное пространство кластеров в взвешенную схему оценки моделей, учитывающую сложность задач как неотъемлемый фактор итогового сравнения.

На первом этапе для каждого кластера вычисляется среднее значение базовой сложности, определяемой как качество работы простых классификаторов, измеренное через MCC. Использование усредненного значения внутри кластера является обоснованным, поскольку кластеризация уже группирует наборы данных с близкими характеристиками признакового пространства и сопоставимым уровнем сложности. В этом смысле каждый кластер можно рассматривать как устойчивое распределение биологических свойств пептидов, а не набор независимых разрозненных бенчмарков. Агрегирование через среднее значение позволяет снизить влияние случайной вариативности отдельных датасетов и уменьшить шум, связанный с ограниченным размером выборки внутри каждого кластера.

На следующем этапе выполняется ранжирование кластеров по возрастанию их средней сложности. В отличие от ранжирования отдельных бенчмарков, здесь упорядочиваются не индивидуальные наблюдения, а группы задач, обладающие схожими структурными свойствами. Это существенно снижает вариативность, а межкластерные различия отражают устойчивые различия в структуре данных.

Полученные упорядоченные кластеры фактически представляют собой дискретное пространство сложности. Вместо попытки описать сложность как непрерывную величину, формируется конечное число уровней сложности, которые интерпретируются аналогично практикам, используемым в стандартных бенчмарках, где задачи часто делятся на категории типа «легкий», «средний» и «сложный». Отличие предлагаемого подхода заключается в том, что такие уровни формируются не экспертно, а автоматически на основе статистических свойств данных.

Для последующего использования в сравнении моделей каждому кластеру присваивается числовой ранг, отражающий его положение в упорядоченной шкале сложности. Однако для корректного взвешивания вкладов различных кластеров в итоговую оценку эмбеддингов используется не сам ранг в линей-

ной форме, а его нелинейное преобразование через функцию softmax:

$$\text{softmax}(z_i) = \frac{e^{z_i}}{\sum_{j=1}^{n} e^{z_j}},$$

где z_i — i-й элемент входного вектора (логит), n — размерность вектора, $\sum_{j=1}^{n} e^{z_j}$ — нормировочная сумма по всем элементам.

Применение softmax в данном контексте имеет теоретическое обоснование в литературе по learning-to-rank и вероятностным моделям ранжирования. В задачах информационного поиска и обучения ранжированию softmax используется для преобразования оценок релевантности в вероятностное распределение по объектам, что позволяет интерпретировать результаты ранжирования как мягкое распределение предпочтений. В частности, подходы типа ListNet и stochastic rank modeling используют softmax-образные преобразования для перехода от детерминированного порядка к вероятностной интерпретации ранга, что обеспечивает согласование с дифференцируемыми функциями потерь и метриками качества ранжирования. В данной работе softmax применяется как механизм преобразования дискретных рангов кластеров в веса, интерпретируемые как относительная значимость соответствующего уровня сложности. Такое преобразование позволяет избежать жесткого доминирования сложных или легких кластеров и формирует гладкое распределение вклада различных уровней сложности в итоговую оценку модели. После получения весов производится расчет взвешенного среднего качества модели, где вклад каждого набора данных определяется как функция сложности его кластера. Таким образом, итоговая метрика отражает не просто среднюю производительность модели по набору задач, а ее ожидаемую эффективность с учетом структуры пространства сложности.

$$Q = \sum_{i=1}^{n} \text{softmax}(r_i)\, q_i, \quad \text{где}$$

где q_i — базовая производительность модели на i-м датасете, измеренная как значение выбранной метрики качества (например, качество линейной регрессии на эмбеддингах), r_i — ранг кластера, к которому принадлежит i-й датасет, отражающий его относительную сложность в пространстве кластеров.

Использование взвешенного среднего вместо простого усреднения без учета сложности является принципиально важным, поскольку стандартное среднее предполагает равную значимость всех датасетов, что в условиях неоднородных бенчмарков приводит к смещению оценки в сторону более простых или более многочисленных задач. В таком случае модель, хорошо работающая на легких датасетах, может получить завышенную итоговую оценку, несмотря на слабую эффективность на сложных задачах.

Предлагаемый подход устраняет это смещение за счет явного учета сложности через структурированное ранжирование кластеров и нелинейное взвешивание их вклада. В результате итоговая оценка отражает не только усредненную производительность модели, но и ее устойчивость к увеличению сложности задач, что является более корректной характеристикой качества биологических языковых моделей в условиях неоднородных и слабо стандартизированных бенчмарков.

Выводы по главе 2

ГЛАВА 3. РЕАЛИЗАЦИЯ И АНАЛИЗ АЛГОРИТМА ДЛЯ СРАВНИТЕЛЬНОГО АНАЛИЗА БИОЛОГИЧЕСКИХ ЯЗЫКОВЫХ МОДЕЛЕЙ

3.1. Контрольные наборы данных

Выбор пептидов в качестве объекта исследования обусловлен сочетанием доступности данных и разнообразия прикладных задач. Пептиды выполняют широкий спектр функций, что привело к активному развитию данной области и формированию большого числа открытых наборов данных, пригодных для систематического анализа.

Для достижения поставленных целей был сформирован репрезентативный набор бенчмарков, охватывающий различные типы задач бинарной классификации. Основным источником послужили работы, ориентированные на сравнение методов кодирования пептидных последовательностей, откуда была заимствована значительная часть используемых наборов данных [2]. Дополнительно были проанализированы исследования, посвященные универсальным архитектурам, способным решать широкий круг задач за счет переобучения на новых данных [110]. Такие работы, как правило, сопровождаются тщательной валидацией и включают разнообразные бенчмарки, что делает их ценным источником данных.

Отдельное внимание уделено наборам данных, связанным с наиболее изученными биологическими свойствами пептидов, включая антимикробную, антидиабетическую, токсическую и противовоспалительную активность. Эти бенчмарки были отобраны из работ, в которых применяются методы машинного обучения для решения прикладных задач. Полный перечень используемых наборов данных с указанием источников приведен в Приложении А. В итоге сформировано 19 категорий, при этом большая половина из них представлена менее чем тремя наборами данных.

3.2. Расчет характеристик сложности

Для каждого набора данных были рассчитаны характеристики сложности, описанные во второй главе, что обеспечило единообразное представление всех бенчмарков в пространстве признаков.

Признаки, отражающие сложность задачи классификации, вычислялись с использованием специализированной библиотеки problexity [65], предостав-

ляющей набор стандартных метрик, применяемых для анализа разделимости классов и структуры данных.

Признаки, характеризующие доменную информативность, были реализованы в рамках данной работы самостоятельно, поскольку существующие решения не покрывают полноценный анализ аминокислотных последовательностей. Для выполнения отдельных вычислительных операций использовались вспомогательные библиотеки Levenshtein [71] и seqshannon [105]. Первая применялась для оценки расстояний редактирования между последовательностями, а вторая использовалась для расчета энтропийных характеристик, отражающих вариативность аминокислотного состава.

Все вычисления выполнены на языке Python, что обеспечило гибкость реализации и удобство интеграции сторонних библиотек. Обработка данных организована с использованием многопроцессорной параллелизации на основе стандартного модуля multiprocessing, что позволило распределить вычислительную нагрузку между несколькими процессами и существенно сократить время расчета признаков при работе с большим числом наборов данных.

Вычисление базовой сложности наборов данных выполнялось с использованием библиотеки scikit-learn [103]. На первом этапе аминокислотные последовательности преобразовывались в числовое представление с использованием разреженного кодирования с добавлением отступов с конца, что обеспечивало унифицированный формат входных данных для моделей. Далее для каждого набора данных формировалась матрица признаков и вектор целевых меток, после чего проводилось обучение и оценка нескольких базовых алгоритмов, представляющих различные семейства методов машинного обучения. В исследовании использовались линейные модели, методы опорных векторов, алгоритмы ближайших соседей, ансамблевые методы на основе решающих деревьев и градиентный бустинг.

Оценка качества моделей выполнялась с применением стратифицированной кросс-валидации, что позволило сохранить баланс классов в разбиениях и обеспечить устойчивость результатов. Для каждого алгоритма рассчитывались три стандартные метрики качества, включающие коэффициент корреляции Мэттьюса, площадь под ROC-кривой и F1-меру. Итоговые значения метрик усреднялись по всем разбиениям, дополнительно оценивалось стандартное отклонение, что позволяло учитывать вариативность результатов.

Параллельное выполнение процедур кросс-валидации реализовано средствами используемой библиотеки, что обеспечило эффективное использование вычислительных ресурсов. Полученные значения метрик использовались в дальнейшем в качестве количественной оценки базовой сложности наборов данных и служили основой для последующего анализа и построения моделей, связывающих признаки сложности с качеством классификации.

3.3. Анализ характеристик сложности

Анализ вычисленных характеристик сложности проводился в два этапа и был направлен на оценку их информативности и устойчивости, а также на выявление признаков, наилучшим образом отражающих базовую сложность наборов данных.

На первом этапе выполнялась предварительная обработка признаков. Все характеристики были стандартизированы путем центрирования и нормировки, что обеспечило сопоставимость их масштабов. Далее исключались признаки с низкой вариативностью, поскольку они не несут значимой информации для последующего анализа. В частности, были удалены такие характеристики, как минимальное расстояние Левенштейна, медианное значение и максимальное нормированное число уникальных тримеров.

После этого проводилась оценка устойчивости признаков. Для каждого набора данных многократно формировались случайные подвыборки, составляющие 80% исходного объема, с последующим пересчетом всех характеристик. На основе полученных значений вычислялся коэффициент вариации[1], отражающий относительную изменчивость признака. Признаки, демонстрирующие высокую нестабильность, исключались из дальнейшего рассмотрения. В качестве порогового значения использовался уровень 10%, что позволило отобрать только устойчивые характеристики. Полноценные результаты этого анлиза представлены в приложении **??**.

Для оставшихся признаков анализировалась их связь с метриками качества базовых моделей, включая MCC, AUC-ROC и F1-меру. Корреляционный анализ, представленные на рисунке **??**, показал наличие статистически значимых зависимостей, однако значения коэффициентов оставались умеренными. Наибольшую корреляцию с базовой сложностью продемонстрировали такие

[1]Коэффициент вариации — это безразмерная мера относительной изменчивости признака, определяемая как отношение стандартного отклонения к среднему значению. Используется для оценки устойчивости характеристик при повторных измерениях.

характеристики, как T1, среднее число уникальных тримеров, средняя длина последовательности и энтропия Шеннона. Значения коэффициента Спирмена находились в диапазоне от 0.3 до 0.57, что указывает на ограниченную объясняющую способность отдельных признаков. Данный результат подтверждает необходимость рассмотрения совокупного вклада характеристик сложности.

Второй этап был направлен на отбор наиболее значимых признаков и построение модели, связывающей их с базовой сложностью. Для этого использовался пайплайн, включающий предварительную стандартизацию и обучение регрессионной модели. В качестве базовых моделей рассматривались линейная регрессия, а также ее регуляризованные варианты, включая Lasso[2] и Ridge[3]. Оценка качества выполнялась с применением пятикратной кросс-валидации с перемешиванием данных, что обеспечивало устойчивость результатов.

Отбор признаков осуществлялся методом последовательного исключения, при котором на каждом шаге удалялись наименее значимые признаки с точки зрения заданной функции качества. В качестве критерия оптимизации использовался коэффициент корреляции Спирмена между предсказанными и истинными значениями целевой переменной, отражающей базовую сложность. После завершения процедуры отбора формировался набор признаков, обеспечивающий наилучшее качество модели.

Для выбранных признаков дополнительно проводилась повторная кросс-валидация, в рамках которой оценивались коэффициент детерминации и корреляция Спирмена. Это позволило количественно оценить вклад отобранных характеристик в объяснение базовой сложности. Полученные результаты показали, что существует ограниченный, но информативный набор признаков, способный адекватно описывать сложность наборов данных.

Проведенный анализ подтверждает, что базовая сложность, определяемая через качество простых моделей, обученных на разреженном кодировании последовательностей, может быть аппроксимирована с использованием специально сконструированных характеристик. Это свидетельствует о том, что

[2]Lasso (Least Absolute Shrinkage and Selection Operator) — метод линейной регрессии с L1-регуляризацией, при которой в функцию потерь добавляется штраф на сумму абсолютных значений коэффициентов. Это приводит к разреженности модели и позволяет выполнять отбор признаков.

[3]Ridge — метод линейной регрессии с L2-регуляризацией, при которой в функцию потерь добавляется штраф на сумму квадратов коэффициентов. Такой подход уменьшает переобучение и стабилизирует оценки параметров модели, не обнуляя их полностью.

предложенные признаки действительно отражают структурные свойства данных и могут использоваться для дальнейшего сравнительного анализа моделей.

3.4. Анализ кластеров сложности

В результате серии экспериментов, направленных на выбор оптимального метода разбиения наборов данных на группы по признакам сложности, наилучшие результаты продемонстрировал алгоритм k-средних. Качество кластеризации оценивалось с использованием нескольких внутренних метрик. Значение коэффициента силуэта составило $0{,}287$, что указывает на умеренную степень разделимости кластеров. Дополнительно был рассчитан коэффициент разделения кластеров, равный $0{,}731$, что показывает достаточно высокую степень разделимости кластеров в понятиях средней базовой сложности и разброса сложности внутри кластеров. Также коэффициент вариации размеров кластеров составил $0{,}479$, что свидетельствует об отсутствии сильного дисбаланса между группами.

Для визуального анализа полученного разбиения использовался метод t-SNE[4]. Визуализация кластеров в двумерном пространстве представлена на рисунке **??**, где наблюдается формирование отдельных групп, соответствующих различным уровням сложности. Сопоставление каждого набора данных с присвоенным кластером приведено в Приложении **??**.

Для проверки статистической значимости различий между полученными группами был применен дисперсионный анализ ANOVA[5]. Проведенный анализ показал наличие статистически значимых различий по совокупности признаков сложности, что подтверждает корректность выделенных кластеров и их интерпретацию как различных типов задач.

Профиль каждого кластера представлен на рисунке **??** в виде радиальной диаграммы по десяти наиболее значимым признакам, отобранным на основе ANOVA. Наблюдаемые различия в форме и масштабе профилей свидетельствуют о том, что выделенные группы существенно отличаются друг от друга

[4]t-SNE — метод нелинейного снижения размерности, предназначенный для визуализации высокоразмерных данных. Он сохраняет локальную структуру данных, отображая близкие объекты в исходном пространстве как близкие точки в пространстве низкой размерности, что делает его удобным инструментом для анализа кластерной структуры.

[5]Дисперсионный анализ (ANOVA) — статистический метод, используемый для проверки гипотезы о равенстве средних значений в нескольких группах, который позволяет определить, существуют ли статистически значимые различия между кластерами по рассматриваемым признакам.

по характеристикам сложности. Это дополнительно подтверждает, что полученное разбиение является интерпретируемым и отражает реальные различия между наборами данных.

Отдельно была проведена оценка стабильности кластеров посредством многократного формирования случайных подвыборок из исходных наборов данных, аналогично процедуре оценки стабильности каждого из признаков. Результаты **??**.

3.5. Сравнение векторных представлений передовых биологических языковых моделей

Для демонстрации практической применимости предложенного подхода проведено тематическое исследование на примере сенсорных пептидов. В рамках собранного корпуса бенчмарков данная категория представлена тремя наборами данных. Каждый из них был отнесен к одному из ранее полученных кластеров с использованием процедуры предсказания принадлежности, основанной на рассчитанных признаках сложности. Поскольку кластеры упорядочены по возрастанию средней сложности, каждому набору данных был присвоен ранг, отражающий относительный уровень сложности задачи.

В качестве объектов сравнения рассматривались современные биологические языковые модели ESM-C, ProtBert, ProtT5 и Ankh. Для каждой модели были извлечены эмбеддинги последовательностей, после чего оценивалась их пригодность для решения задач бинарной классификации с использованием стандартных алгоритмов машинного обучения. В эксперименте использовались следующие семейства методов:

— линейные модели, представленные логистической регрессией;
— методы опорных векторов;
— алгоритмы ближайших соседей;
— ансамблевые методы на основе решающих деревьев;
— методы градиентного бустинга.

Оценка качества выполнялась с применением пятикратной кросс-валидации. Для каждого набора данных и каждой языковой модели выбиралось наилучшее значение коэффициента корреляции Мэттьюса, усредненное по всем результатам пятикратной перекрестной проверки и максимизированное по всем использованным алгоритмам классификации. Таким образом, каждому набору данных сопоставлялись его ранг сложности и наилучшая достиг-

нутая производительность для эмбеддингов каждой из рассматриваемых моделей.

На следующем этапе проводилось сравнение языковых моделей по их способности выявлять сенсорные свойства пептидов. Для этого рассчитывались два варианта агрегированной метрики качества. В первом случае использовалось простое среднее значение по всем наборам данных. Во втором случае применялось взвешенное среднее, в котором вклад каждого набора данных определялся его относительной сложностью. Веса формировались на основе рангов сложности с использованием функции softmax, что позволяло увеличить влияние более сложных задач при сохранении нормировки.

Результаты сравнения представлены в таблице **??**. Переход к взвешенному усреднению приводит к изменению лидирующей модели. Если при использовании обычного среднего наилучший результат демонстрирует ProtT5, то с учетом сложности наборов данных преимущество переходит к ESM-C, которая показывает более высокое качество на задачах повышенной сложности.

Аналогичный анализ был проведен для всех категорий бенчмарков, содержащих не менее двух наборов данных. В результате установлено, что в 23% случаев выбор наилучшей модели изменяется при учете сложности задач. Полная сводка результатов приведена в Приложении **??**. При этом в целом по совокупности категорий модель ProtT5 сохраняет лидерство как по обычному, так и по взвешенному среднему, что указывает на ее высокую универсальность, тогда как учет сложности позволяет выявить модели, более эффективные на трудных задачах.

Выводы по главе 3

ЗАКЛЮЧЕНИЕ

В данном разделе размещается заключение.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1 *Левенштейн В. И.* Двоичные коды с исправлением выпадений, вставок и замещений символов // Доклады АН СССР. — 1965. — № 163. — С. 707–710.

2 A large-scale comparative study on peptide encodings for biomedical classification / S. Spänig [и др.] // NAR genomics and bioinformatics. — 2021. — Т. 3, № 2. — lqab039.

3 A web server and mobile app for computing hemolytic potency of peptides / K. Chaudhary [и др.] // Scientific reports. — 2016. — Т. 6, № 1. — С. 22843.

4 AAindex: amino acid index database, progress report 2008 / S. Kawashima [и др.] // Nucleic acids research. — 2007. — Т. 36, suppl_1. — С. D202–D205.

5 AIPpred: sequence-based prediction of anti-inflammatory peptides using random forest / B. Manavalan [и др.] // Frontiers in pharmacology. — 2018. — Т. 9. — С. 276.

6 AIPs-SnTCN: Predicting anti-inflammatory peptides using fastText and transformer encoder-based hybrid word embedding with self-normalized temporal convolutional networks / A. Raza [и др.] // Journal of chemical information and modeling. — 2023. — Т. 63, № 21. — С. 6537–6554.

7 Alignment-free antimicrobial peptide predictors: improving performance by a thorough analysis of the largest available data set / S. A. Pinacho-Castellanos [и др.] // Journal of Chemical Information and Modeling. — 2021. — Т. 61, № 6. — С. 3141–3157.

8 An FPGA implementation to detect selective cationic antibacterial peptides / C. Polanco González [и др.] // PloS one. — 2011. — Т. 6, № 6. — e21399.

9 Ankh : Optimized Protein Language Model Unlocks General-Purpose Modelling / A. Elnaggar [и др.] // bioRxiv. — 2023. — DOI: `10.1101/2023.01.16.524265`. — eprint: `https://www.biorxiv.org/content/early/2023/01/18/2023.01.16.524265.full.pdf`. — URL: `https://www.biorxiv.org/content/early/2023/01/18/2023.01.16.524265`.

10 AnOxPePred: using deep learning for the prediction of antioxidative properties of peptides / T. H. Olsen [и др.] // Scientific reports. — 2020. — Т. 10, № 1. — С. 21471.

11 AntiCP 2.0: an updated model for predicting anticancer peptides / P. Agrawal [и др.] // Briefings in bioinformatics. — 2021. — Т. 22, № 3. — bbaa153.

12 Antimicrobial peptide identification using multi-scale convolutional network / X. Su [и др.] // BMC bioinformatics. — 2019. — Т. 20, № 1. — С. 730.

13 Application of support vector machines for T-cell epitopes prediction / Y. Zhao [и др.] // Bioinformatics. — 2003. — Т. 19, № 15. — С. 1978–1984.

14 ATSE: a peptide toxicity predictor by exploiting structural and evolutionary information based on graph neural network and attention mechanism / L. Wei [и др.] // Briefings in bioinformatics. — 2021. — Т. 22, № 5. — bbab041.

15 *Barabási A.-L.*, *Gulbahce N.*, *Loscalzo J.* Network medicine: a network-based approach to human disease // Nature reviews genetics. — 2011. — Т. 12, № 1. — С. 56–68.

16 BBPpred: sequence-based prediction of blood-brain barrier peptides with feature representation learning and logistic regression / R. Dai [и др.] // Journal of Chemical Information and Modeling. — 2021. — Т. 61, № 1. — С. 525–534.

17 *Berger B.*, *Waterman M. S.*, *Yu Y. W.* Levenshtein Distance, Sequence Comparison and Biological Database Search // IEEE Transactions on Information Theory. — 2021. — Т. 67, № 6. — С. 3287–3294. — DOI: 10.1109/TIT.2020.2996543.

18 Bert: Pre-training of deep bidirectional transformers for language understanding / J. Devlin [и др.] // Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers). — 2019. — С. 4171–4186.

19 BERT4Bitter: a bidirectional encoder representations from transformers (BERT)-based model for improving the prediction of bitter peptides / P. Charoenkwan [и др.] // Bioinformatics. — 2021. — Т. 37, № 17. — С. 2556–2562.

20 Biological structure and function emerge from scaling unsupervised learning to 250 million protein sequences / A. Rives [и др.] // Proceedings of the national academy of sciences. — 2021. — Т. 118, № 15. — e2016239118.

21 *Chen X.*, *Huang J.*, *He B.* AntiDMPpred: a web service for identifying anti-diabetic peptides // PeerJ. — 2022. — Т. 10. — e13581.

22 *Collins E.*, *Rozanov N.*, *Zhang B.* Evolutionary data measures: Understanding the difficulty of text classification tasks // Proceedings of the 22nd Conference on Computational Natural Language Learning. — 2018. — С. 380–391.

23 Computational design of highly selective antimicrobial peptides / D. Juretic [и др.] // Journal of chemical information and modeling. — 2009. — Т. 49, № 12. — С. 2873–2882.

24 Computer-aided designing of immunosuppressive peptides based on IL-10 inducing potential / G. Nagpal [и др.] // Scientific reports. — 2017. — Т. 7, № 1. — С. 42851.

25 Computer-aided prediction of antigen presenting cell modulators for designing peptide-based vaccine adjuvants / G. Nagpal [и др.] // Journal of translational medicine. — 2018. — Т. 16, № 1. — С. 181.

26 Connecting peptide physicochemical and antimicrobial properties by a rational prediction model / M. Torrent [и др.] // PloS one. — 2011. — Т. 6, № 2. — e16968.

27 CPPred-FL: a sequence-based predictor for large-scale identification of cell-penetrating peptides by feature representation learning / X. Qiang [и др.] // Briefings in Bioinformatics. — 2020. — Т. 21, № 1. — С. 11–23.

28 Deep learning on chaos game representation for proteins / H. F. Löchel [и др.] // Bioinformatics. — 2020. — Янв. — Т. 36, № 1. — С. 272–279. — ISSN 1367-4803. — DOI: `10.1093/bioinformatics/btz493`. — eprint: `https://academic.oup.com/bioinformatics/article-pdf/36/1/272/48981566/bioinformatics_36_1_272.`

pdf. — URL: https://doi.org/10.1093/bioinformatics/btz493.

29 Deep learning on chaos game representation for proteins / H. F. Löchel [и др.] // Bioinformatics. — 2020. — Т. 36, № 1. — С. 272–279.

30 DeepAffinity: interpretable deep learning of compound–protein affinity through unified recurrent and convolutional neural networks / M. Karimi [и др.] // Bioinformatics. — 2019. — Т. 35, № 18. — С. 3329–3338.

31 DeepCAPE: a deep convolutional neural network for the accurate prediction of enhancers / S. Chen [и др.] // Genomics, Proteomics & Bioinformatics. — 2021. — Т. 19, № 4. — С. 565–577.

32 Designing antimicrobial peptides using deep learning and molecular dynamic simulations / Q. Cao [и др.] // Briefings in Bioinformatics. — 2023. — Т. 24, № 2. — bbad058.

33 *Dybowski J. N.*, *Heider D.*, *Hoffmann D.* Prediction of co-receptor usage of HIV-1 from genotype // PLoS computational biology. — 2010. — Т. 6, № 4. — e1000743.

34 *Eddy S. R.* Where did the BLOSUM62 alignment score matrix come from? // Nature biotechnology. — 2004. — Т. 22, № 8. — С. 1035–1036.

35 *Elmakias I.*, *Vilenchik D.* Choosing the right dataset: Hardness criteria for feature selection benchmarking // Knowledge-Based Systems. — 2025. — С. 115022.

36 Evaluating protein transfer learning with TAPE / R. Rao [и др.] // Advances in neural information processing systems. — 2019. — Т. 32.

37 Evolutionary-scale prediction of atomic-level protein structure with a language model / Z. Lin [и др.] // Science. — 2023. — Т. 379, № 6637. — С. 1123–1130.

38 Exploring the limits of transfer learning with a unified text-to-text transformer / C. Raffel [и др.] // Journal of machine learning research. — 2020. — Т. 21, № 140. — С. 1–67.

39 *Fernandes F. C.*, *Rigden D. J.*, *Franco O. L.* Prediction of antimicrobial peptides based on the adaptive neuro-fuzzy inference system application // Peptide Science. — 2012. — Т. 98, № 4. — С. 280–287.

40 Grammar of protein domain architectures / L. Yu [и др.] // Proceedings of the National Academy of Sciences. — 2019. — Т. 116, № 9. — С. 3636–3645. — DOI: 10.1073/pnas.1814684116. — eprint: https://www.pnas.org/doi/pdf/10.1073/pnas.1814684116. — URL: https://www.pnas.org/doi/abs/10.1073/pnas.1814684116.

41 *Han P.*, *Zhang X.*, *Feng Z.-P.* Predicting disordered regions in proteins using the profiles of amino acid indices // Bmc Bioinformatics. — 2009. — Т. 10, Suppl 1. — S42.

42 *Hansen M.*, *Kilk K.*, *Langel Ü.* Predicting cell-penetrating peptides // Advanced drug delivery reviews. — 2008. — Т. 60, № 4/5. — С. 572–579.

43 *Heider D.*, *Hoffmann D.* Interpol: An R package for preprocessing of protein sequences // BioData mining. — 2011. — Т. 4, № 1. — С. 16.

44 *Heider D.*, *Verheyen J.*, *Hoffmann D.* Predicting Bevirimat resistance of HIV-1 from genotype // BMC bioinformatics. — 2010. — Т. 11, № 1. — С. 37.

45 *Heider D.*, *Verheyen J.*, *Hoffmann D.* Machine learning on normalized protein sequences // BMC research notes. — 2011. — Т. 4, № 1. — С. 94.

46 Highly accurate protein structure prediction with AlphaFold / J. Jumper [и др.] // nature. — 2021. — Т. 596, № 7873. — С. 583–589.

47 *Hirst J. D.*, *Sternberg M. J.* Prediction of structural and functional features of protein and nucleic acid sequences by artificial neural networks // Biochemistry. — 1992. — Т. 31, № 32. — С. 7211–7218.

48 *Ho T. K.*, *Basu M.* Complexity measures of supervised classification problems // IEEE Transactions on Pattern Analysis and Machine Intelligence. — 2002. — Т. 24, № 3. — С. 289–300. — DOI: 10.1109/34.990132.

49 How Complex Is Your Classification Problem? A Survey on Measuring Classification Complexity / A. C. Lorena [и др.] // ACM Comput. Surv. — New York, NY, USA, 2019. — Сент. — Т. 52, № 5. — ISSN 0360-0300. — DOI: 10.1145/3347711. — URL: https://doi.org/10.1145/3347711.

50 iACP: a sequence-based tool for identifying anticancer peptides / W. Chen [и др.] // Oncotarget. — 2016. — Т. 7, № 13. — С. 16895.

51 iAMAP-SCM: a novel computational tool for large-scale identification of antimalarial peptides using estimated propensity scores of dipeptides / P. Charoenkwan [и др.] // ACS omega. — 2022. — Т. 7, № 45. — С. 41082–41095.

52 iAMP-2L: a two-level multi-label classifier for identifying antimicrobial peptides and their functional types / X. Xiao [и др.] // Analytical biochemistry. — 2013. — Т. 436, № 2. — С. 168–177.

53 iBCE-EL: a new ensemble learning framework for improved linear B-cell epitope prediction / B. Manavalan [и др.] // Frontiers in immunology. — 2018. — Т. 9. — С. 1695.

54 iDPPIV-SCM: a sequence-based predictor for identifying and analyzing dipeptidyl peptidase IV (DPP-IV) inhibitory peptides using a scoring card method / P. Charoenkwan [и др.] // Journal of proteome research. — 2020. — Т. 19, № 10. — С. 4125–4136.

55 Improved prediction and characterization of anticancer activities of peptides using a novel flexible scoring card method / P. Charoenkwan [и др.] // Scientific reports. — 2021. — Т. 11, № 1. — С. 3017.

56 In silico approach for prediction of antifungal peptides / P. Agrawal [и др.] // Frontiers in microbiology. — 2018. — Т. 9. — С. 323.

57 In silico approaches for designing highly effective cell penetrating peptides / A. Gautam [и др.] // Journal of translational medicine. — 2013. — Т. 11, № 1. — С. 74.

58 In silico models for designing and discovering novel anticancer peptides / A. Tyagi [и др.] // Scientific reports. — 2013. — Т. 3, № 1. — С. 2984.

59 Integrating transformer and imbalanced multi-label learning to identify antimicrobial peptides and their functional activities / Y. Pang [и др.] // Bioinformatics. — 2022. — Т. 38, № 24. — С. 5368–5374.

60 iPromoter-Seqvec: identifying promoters using bidirectional long short-term memory and sequence-embedded features / T.-H. Nguyen-Vo [и др.] // BMC genomics. — 2022. — Т. 23, Suppl 5. — С. 681.

61 iTTCA-Hybrid: Improved and robust identification of tumor T cell antigens by utilizing hybrid feature representation / P. Charoenkwan [и др.] // Analytical biochemistry. — 2020. — Т. 599. — С. 113747.

62 iUmami-SCM: a novel sequence-based predictor for prediction and analysis of umami peptides using a scoring card method with propensity scores of dipeptides / P. Charoenkwan [и др.] // Journal of Chemical Information and Modeling. — 2020. — Т. 60, № 12. — С. 6666–6678.

63 KELM-CPPpred: Kernel extreme learning machine based prediction model for cell-penetrating peptides / P. Pandey [и др.] // Journal of proteome research. — 2018. — Т. 17, № 9. — С. 3214–3222.

64 *Khatun S.*, *Hasan M.*, *Kurata H.* Efficient computational model for identification of antitubercular peptides by integrating amino acid patterns and properties // FEBS letters. — 2019. — Т. 593, № 21. — С. 3029–3039.

65 *Komorniczak J.*, *Ksieniewicz P.* problexity—an open-source python library for supervised learning problem complexity assessment // Neurocomputing. — 2023. — Т. 521. — С. 126–136.

66 *Kruskal J. B.* An Overview of Sequence Comparison: Time Warps, String Edits, and Macromolecules // SIAM Review. — 1983. — Т. 25, № 2. — С. 201–237. — DOI: `10.1137/1025045`. — eprint: `https://doi.org/10.1137/1025045`. — URL: `https://doi.org/10.1137/1025045`.

67 *Kulmanov M.*, *Hoehndorf R.* DeepGOPlus: improved protein function prediction from sequence // Bioinformatics. — 2020. — Т. 36, № 2. — С. 422–429.

68 Large language models generate functional protein sequences across diverse families / A. Madani [и др.] // Nature biotechnology. — 2023. — Т. 41, № 8. — С. 1099–1106.

69 *Lata S.*, *Sharma B.*, *Raghava G. P.* Analysis and prediction of antibacterial peptides // BMC bioinformatics. — 2007. — Т. 8, № 1. — С. 263.

70 *Leslie C.*, *Eskin E.*, *Noble W. S.* The spectrum kernel: A string kernel for SVM protein classification // Biocomputing 2002. — World Scientific, 2001. — С. 564–575.

71 Levenshtein Documentation [Электронный ресурс]. — URL: https://rapidfuzz.github.io/Levenshtein/ (дата обр. 20.04.2026).

72 Machine-learning-based prediction of cell-penetrating peptides and their uptake efficiency with improved accuracy / B. Manavalan [и др.] // Journal of proteome research. — 2018. — Т. 17, № 8. — С. 2715–2726.

73 mAHTPred: a sequence-based meta-predictor for improving the prediction of anti-hypertensive peptides using effective feature representation / B. Manavalan [и др.] // Bioinformatics. — 2019. — Т. 35, № 16. — С. 2757–2765.

74 MLACP: machine-learning-based prediction of anticancer peptides / B. Manavalan [и др.] // Oncotarget. — 2017. — Т. 8, № 44. — С. 77121.

75 Modeling aspects of the language of life through transfer-learning protein sequences / M. Heinzinger [и др.] // BMC bioinformatics. — 2019. — Т. 20, № 1. — С. 723.

76 modlAMP: Python for antimicrobial peptides / A. T. Müller [и др.] // Bioinformatics. — 2017. — Т. 33, № 17. — С. 2753–2755.

77 *Naamati G.*, *Askenazi M.*, *Linial M.* ClanTox: a classifier of short animal toxins // Nucleic acids research. — 2009. — Т. 37, suppl_2. — W363–W368.

78 NetSurfP-2.0: Improved prediction of protein structural features by integrated deep learning / M. S. Klausen [и др.] // Proteins: Structure, Function, and Bioinformatics. — 2019. — Т. 87, № 6. — С. 520–527.

79 Neural network and random forest models in protein function prediction / K. Hakala [и др.] // IEEE/ACM transactions on computational biology and bioinformatics. — 2020. — Т. 19, № 3. — С. 1772–1781.

80 NeuroPIpred: a tool to predict, design and scan insect neuropeptides / P. Agrawal [и др.] // Scientific Reports. — 2019. — Т. 9, № 1. — С. 5129.

81 NeuroPred-CLQ: incorporating deep temporal convolutional networks and multi-head attention mechanism to predict neuropeptides / S. Chen [и др.] // Briefings in Bioinformatics. — 2022. — Т. 23, № 5. — bbac319.

82 New chemical descriptors relevant for the design of biologically active peptides. A multivariate characterization of 87 amino acids / M. Sandberg [и др.] // Journal of medicinal chemistry. — 1998. — Т. 41, № 14. — С. 2481–2491.

83 *Ofer D.*, *Brandes N.*, *Linial M.* The language of proteins: NLP, machine learning & protein sequences // Computational and Structural Biotechnology Journal. — 2021. — Т. 19. — С. 1750–1758.

84 *Ofer D.*, *Linial M.* ProFET: Feature engineering captures high-level protein functions // Bioinformatics. — 2015. — Т. 31, № 21. — С. 3429–3436.

85 PIP-EL: a new ensemble learning method for improved proinflammatory peptide predictions / B. Manavalan [и др.] // Frontiers in immunology. — 2018. — Т. 9. — С. 1783.

86 *Plisson F.*, *Ramírez-Sánchez O.*, *Martínez-Hernández C.* Machine learning-guided discovery and design of non-hemolytic peptides // Scientific reports. — 2020. — Т. 10, № 1. — С. 16581.

87 Plptp: a motif-based interpretable deep learning framework based on protein language models for peptide toxicity prediction / S. Gao [и др.] // Journal of Molecular Biology. — 2025. — Т. 437, № 12. — С. 169115.

88 *Porto W. F.*, *Pires Á. S.*, *Franco O. L.* CS-AMPPred: an updated SVM model for antimicrobial activity prediction in cysteine-stabilized peptides // PLoS One. — 2012. — Т. 7, № 12. — e51444.

89 PredAPP: predicting anti-parasitic peptides with undersampling and ensemble approaches / W. Zhang [и др.] // Interdisciplinary Sciences: Computational Life Sciences. — 2022. — Т. 14, № 1. — С. 258–268.

90 Predicting antimicrobial peptides with improved accuracy by incorporating the compositional, physico-chemical and structural features into Chou's general PseAAC / P. K. Meher [и др.] // Scientific reports. — 2017. — Т. 7, № 1. — С. 42362.

91 Prediction of anti-inflammatory proteins/peptides: an insilico approach / S. Gupta [и др.] // Journal of translational medicine. — 2017. — Т. 15, № 1. — С. 7.

92 Prediction of antioxidant peptides using a quantitative structure- activity relationship predictor (AnOxPP) based on bidirectional long short-term memory neural network and interpretable amino acid descriptors / D. Qin [и др.] // Computers in Biology and Medicine. — 2023. — Т. 154. — С. 106591.

93 Prediction of cell-penetrating peptides using artificial neural networks / D. A. Dobchev [и др.] // Current computer-aided drug design. — 2010. — Т. 6, № 2. — С. 79–89.

94 Prediction of cell-penetrating potential of modified peptides containing natural and chemically modified residues / V. Kumar [и др.] // Frontiers in microbiology. — 2018. — Т. 9. — С. 725.

95 ProtTrans: toward understanding the language of life through self-supervised learning / A. Elnaggar [и др.] // IEEE transactions on pattern analysis and machine intelligence. — 2021. — Т. 44, № 10. — С. 7112–7127.

96 Rdkit documentation / G. Landrum [и др.] // Release. — 2013. — Т. 1, № 1–79. — С. 4.

97 Real time metagenomics: using k-mers to annotate metagenomes / R. A. Edwards [и др.] // Bioinformatics. — 2012. — Т. 28, № 24. — С. 3316–3317.

98 Recommendations for the presentation of NMR structures of proteins and nucleic acids–IUPAC-IUBMB-IUPAB Inter-Union Task Group on the standardization of data bases of protein and nucleic acid structures determined by NMR spectroscopy / J. L. Markley [и др.] // Journal of biomolecular NMR. — 1998. — Т. 12, № 1. — С. 1–23.

99 Reduced amino acid alphabet is sufficient to accurately recognize intrinsically disordered protein / E. A. Weathers [и др.] // FEBS letters. — 2004. — Т. 576, № 3. — С. 348–352.

100 Reliable prediction of T-cell epitopes using neural networks with novel sequence representations / M. Nielsen [и др.] // Protein Science. — 2003. — Т. 12, № 5. — С. 1007–1017.

101 *Rögnvaldsson T.*, *You L.*, *Garwicz D.* State of the art prediction of HIV-1 protease cleavage sites // Bioinformatics. — 2015. — Т. 31, № 8. — С. 1204–1210.

102 *Salton G.*, *Buckley C.*, *Fox E. A.* Automatic query formulations in information retrieval // Journal of the American society for information science. — 1983. — Т. 34, № 4. — С. 262–280.

103 scikit-learn [Электронный ресурс]. — URL: `https://scikit-learn.org/stable/index.html/` (дата обр. 20.04.2026).

104 SCMRSA: a new approach for identifying and Analyzing anti-MRSA peptides using estimated propensity scores of dipeptides / P. Charoenkwan [и др.] // ACS omega. — 2022. — Т. 7, № 36. — С. 32653–32664.

105 seqshannon [Электронный ресурс]. — URL: `https://pypi.org/project/seqshannon/` (дата обр. 20.04.2026).

106 *Spänig S.*, *Heider D.* Encodings and models for antimicrobial peptide classification for multi-resistant pathogens // BioData Mining. — 2019. — Т. 12, № 1. — С. 7.

107 *Thakur N.*, *Qureshi A.*, *Kumar M.* AVPpred: collection and prediction of highly effective antiviral peptides // Nucleic acids research. — 2012. — Т. 40, W1. — W199–W204.

108 *Timmons P. B.*, *Hewage C. M.* HAPPENN is a novel tool for hemolytic activity prediction for therapeutic peptides which employs neural networks // Scientific reports. — 2020. — Т. 10, № 1. — С. 10869.

109 Ultrahigh-throughput discovery of promiscuous enzymes by picodroplet functional metagenomics / Y. Pierre [и др.] // Nat Commun. — 2015. — Т. 6. — С. 10008.

110 UniDL4BioPep: a universal deep learning architecture for binary classification in peptide bioactivity / Z. Du [и др.] // Briefings in Bioinformatics. — 2023. — Т. 24, № 3. — bbad135.

111 Unified rational protein engineering with sequence-based deep representation learning / E. C. Alley [и др.] // Nature methods. — 2019. — Т. 16, № 12. — С. 1315–1322.

112 UniProt: the universal protein knowledgebase in 2021 // Nucleic acids research. — 2021. — Т. 49, № D1. — С. D480–D489.

113 UniProt: the universal protein knowledgebase in 2023 // Nucleic acids research. — 2023. — Т. 51, № D1. — С. D523–D531.

114 UniProtKB/Swiss-Prot / E. Boutet [и др.] // Plant Bioinformatics: Methods and Protocols / под ред. D. Edwards. — Totowa, NJ : Humana Press, 2007. — С. 89–112. — ISBN 978-1-59745-535-0. — DOI: 10.1007/978-1-59745-535-0_4. — URL: https://doi.org/10.1007/978-1-59745-535-0_4.

115 UniRef: comprehensive and non-redundant UniProt reference clusters / B. E. Suzek [и др.] // Bioinformatics. — 2007. — Т. 23, № 10. — С. 1282–1288.

116 *Usmani S. S.*, *Bhalla S.*, *Raghava G. P.* Prediction of antitubercular peptides from sequence information using ensemble classifier and hybrid features // Frontiers in pharmacology. — 2018. — Т. 9. — С. 954.

117 *Vinga S.*, *Almeida J.* Alignment-free sequence comparison—a review // Bioinformatics. — 2003. — Т. 19, № 4. — С. 513–523.

118 *Wei H.*, *Liu B.* iCircDA-MF: identification of circRNA-disease associations based on matrix factorization // Briefings in bioinformatics. — 2020. — Т. 21, № 4. — С. 1356–1367.

ПРИЛОЖЕНИЕ А. ИСПОЛЬЗУЕМЫЕ НАБОРЫ ДАННЫХ

Таблица А.1 – Полный перечень использованных наборов данных для задач бинарной классификации пептидов, сгруппированных по типу биологической активности. Для каждого набора указан введённый идентификатор, число положительных (класс 1) и отрицательных (класс 0) примеров, а также источник данных.

Тип активности	Идентификатор	Положительные примеры	Отрицательные примеры	Источник
Антигипертензивные	AHT-1	303	385	[25]
	AHT-2	1299	1299	[73]
Противовоспалительные	INF-1	1451	2339	[6]
	INF-2	863	1261	[91]
	INF-3	420	629	[5]
Антибактериальные	AB-1	148	847	[104]
	AB-2	8278	8278	[7]
	AB-3	246	246	[116]
	AB-4	246	246	[64]
Противоопухолевые	ANT-1	224	225	[58]
	ANT-2	187	398	[74]
	ANT-3	138	206	[50]
	ANT-4	970	970	[55]
	ANT-5	861	861	[11]
	ANT-6	592	393	[61]
Антидиабетические	AD-1	236	236	[21]
	AD-2	664	665	[54]
Противогрибковые	AF-1	1459	1457	[56]
	AF-2	1329	1384	[90]
	AF-3	993	993	[7]
Противопаразитарные	AP-1	138	677	[51]
	AP-2	138	2069	[51]
	AP-3	290	916	[89]
Антимикробные	AMP-1	1225	1354	[76]
	AMP-2	999	994	[12]
	AMP-3	878	2405	[52]
	AMP-4	431	430	[69]
	AMP-5	128	76	[88]
	AMP-6	115	116	[39]
	AMP-7	27	102	[8]
	AMP-8	4134	4134	[32]

Тип активности	Идентифи-катор	Положитель-ные	Отрицатель-ные	Источник
	AMP-9	6282	4707	[59]
Противоокислительные	AO-1	1060	1060	[92]
	AO-2	687	717	[10]
Противовирусные	AV-1	721	739	[90]
	AV-2	598	448	[107]
	AV-3	2944	2944	[7]
	AV-4	43	112	[44]
	AV-5	149	798	[101]
	AV-6	200	1151	[33]
	AV-7	351	234	[28]
	AV-8	324	311	[29]
	AV-9	188	228	[29]
	AV-10	249	403	[29]
	AV-11	291	315	[29]
	AV-12	385	253	[29]
Вкусовые	TASTE-1	320	320	[19]
	TASTE-2	140	302	[62]
ГЭБ-проникающие	BBB-1	119	119	[16]
Проникающие в клетки	CPP-1	1165	738	[93]
	CPP-2	807	807	[57]
	CPP-3	732	730	[94]
	CPP-4	504	499	[63]
	CPP-5	462	462	[27]
	CPP-6	187	187	[72]
	CPP-7	111	34	[72]
Гемолитические	HEM-1	1543	2195	[108]
	HEM-2	522	582	[3]
	HEM-3	552	552	[86]
	HEM-4	552	462	[86]
	HEM-5	884	738	[86]
Иммуносупрессивные	IMM-1	394	848	[24]
Сенсорные	SEN-1	1110	1408	[53]
	SEN-2	36	167	[13]
	SEN-3	218	214	[118]
Нейропептиды	NP-1	2425	2425	[81]
	NP-2	875	875	[80]
Провоспалительные	PINF-1	833	2395	[85]
Токсичные	TOX-1	2138	5375	[87]
	TOX-2	1932	1932	[14]